ECOLE MAROCAINE DES SCIENCES DE L'INGENIEUR
Membre de HONORIS UNITED UNIVERSITIES
EMSI
Ecole Reconnue par l'Etat

RAPPORT DE FIN D'ANNEE :
4éme Année en Ingénierie en Data Science

Conception d'une Plateforme Multi-Agents pour la Régulation Proactive des Bâtiments Intelligents

Réalisé par : Belayachi Adnane

Encadrant Pédagogique : Mossab Batal

Année universitaire : 2025 / 2026

Table des matières

- Table des figures
- Liste des tableaux
- Liste des acronymes
- Introduction Générale
- CHAPITRE 1 : Présentation du Projet, Contexte et Objectifs
- CHAPITRE 2 : État de l'Art
- CHAPITRE 3 : Exploration, analyse et préparation des données environnementales
- CHAPITRE 4 : Conception et développement des modèles de prédiction environnementale
- CHAPITRE 5 : Conception du système intelligent multi-agents et du RAG contextuel
- CHAPITRE 6 : Architecture globale et implémentation de la plateforme intelligente
- Conclusion Générale
- Bibliographie

Table des figures

- Figure 1.1 : Web of Things Architecture
- Figure 1.2 : IoT Architecture
- Figure 1.3 : Seuils de concentration en CO_2 en milieu clos et impacts cognitifs
- Figure 1.4 : LSTM Cell
- Figure 1.5 : Architecture et flux opérationnel du Contextual RAG
- Figure 1.6 : Orchestration collaborative au sein du système multi-agents
- Figure 1.7 : Pipeline cyber-physique et cognitif de bout-en-bout
- Figure 3.1 : Raw Data
- Figure 3.2 : Bilan des valeurs manquantes
- Figure 3.3 : Distributions
- Figure 3.4 : Matrice de corrélation
- Figure 3.5 : Moyennes horaires
- Figure 4.1 : Échec du Random Forest
- Figure 4.2 : Bilan final des modèles Deep Learning
- Figure 4.3 : Convergence du Temporal CNN (Loss)
- Figure 4.4 : Comparaison des erreurs RMSE
- Figure 4.5 : Prédiction vs Réalité
- Figure 5.1 : Analyse de la base de connaissances du RAG Contextuel
- Figure 5.2 : Projection t-SNE de l'espace latent des documents normatifs (Embeddings à 768 dimensions)
- Figure 5.3 : Diagramme décisionnel asynchrone et État Partagé
- Figure 6.1 : Dashboard environnemental (T0)
- Figure 6.2 : Panneau de simulation du profil de l'occupant
- Figure 6.3 : Diagnostic du système multi-agents
- Figure 6.4 : Plan d'Action GTB et traçabilité RAG

Liste des tableaux

- Tableau 1 : Étude comparative de quelques travaux existants
- Tableau 2 : Structure du dataset
- Tableau 3 : Analyse statistique descriptive
- Tableau 4 : Technologies utilisées

Liste des acronymes

- **API** : Application Programming Interface
- **ASHRAE** : American Society of Heating, Refrigerating and Air-Conditioning Engineers
- **CNN** : Convolutional Neural Network
- **GRU** : Gated Recurrent Unit
- **GTB** : Gestion Technique du Bâtiment
- **IoT** : Internet of Things
- **LLM** : Large Language Model
- **LSTM** : Long Short-Term Memory
- **MAE** : Mean Absolute Error
- **OMS** : Organisation Mondiale de la Santé
- **RAG** : Retrieval-Augmented Generation
- **RMSE** : Root Mean Squared Error
- **RNN** : Recurrent Neural Network

Introduction Générale

La transformation digitale et la transition énergétique constituent aujourd'hui les deux axes stratégiques majeurs autour desquels se réorganise la gestion des infrastructures modernes. Cette mutation ne se limite plus à la simple informatisation des processus existants ou à la supervision à distance ; elle s'accompagne désormais d'une intégration croissante de l'intelligence artificielle et de la science des données au cœur même des environnements physiques. Nous passons la majeure partie de notre temps à l'intérieur de bâtiments, des espaces qui, grâce à la prolifération de l'Internet des Objets (IoT), sont désormais capables de générer des flux massifs et continus de données sur leur propre état : température, taux d'humidité, concentration en dioxyde de carbone, luminosité, ou encore détection de présence.

Pourtant, dans la grande majorité des infrastructures actuelles, y compris au sein de complexes universitaires et tertiaires récents, cette masse d'informations reste sous-exploitée. Les systèmes de Gestion Technique du Bâtiment (GTB) traditionnels se contentent d'appliquer des règles de contrôle strictement réactives, fondées sur des seuils statiques préprogrammés. Ils déclenchent par exemple une ventilation uniquement lorsque l'air est déjà vicié, ou activent la climatisation une fois l'inconfort thermique formellement détecté. Au-delà de la perte d'efficacité énergétique évidente qu'engendre cette logique réactive, cette approche purement mécanique néglige une réalité physiologique fondamentale : l'impact direct, immédiat et documenté de la qualité de l'environnement intérieur sur la santé, la concentration et le bien-être général des usagers.

C'est de ce constat concret et de ces limites technologiques qu'est né le présent projet de fin d'études, développé autour des infrastructures du Smart Campus de l'Université d'Oulu en Finlande. L'ambition centrale de ce travail n'est pas de concevoir un énième tableau de bord de surveillance IoT, mais de repenser l'architecture décisionnelle du bâtiment en lui insufflant une capacité de réflexion anticipative. L'objectif est de transformer un bâtiment passif en un environnement proactif, capable d'anticiper ses propres dégradations thermodynamiques pour protéger préventivement ses occupants, tout en tenant compte de leurs sensibilités médicales spécifiques.

Pour relever ce défi d'ingénierie qui se situe à la croisée de la physique du bâtiment et de l'informatique cognitive, nous avons modélisé et implémenté une plateforme d'intelligence artificielle en deux phases distinctes mais complémentaires. La première étape s'appuie sur l'apprentissage profond (Deep Learning), plus précisément sur des réseaux de neurones convolutifs temporels, pour ingérer les séries temporelles issues des capteurs et prédire l'état thermodynamique de la pièce à court terme. La seconde étape, qui constitue le cœur cognitif et décisionnel du système, délègue le raisonnement à une architecture multi-agents. Au lieu d'appliquer des seuils d'alerte binaires, ces agents virtuels spécialisés croisent les prédictions climatiques avec des profils de santé configurables, et interrogent de manière autonome une base de normes officielles de santé publique via une approche de Contextual RAG (Retrieval-Augmented Generation). Le système dépasse ainsi la simple réaction : il anticipe le risque, le contextualise médicalement, et justifie ses recommandations d'intervention technique par des preuves documentaires irréfutables.

Le chapitre 1 de ce mémoire présente en détail le contexte précis du projet, la problématique d'ingénierie qui en découle, les objectifs poursuivis, ainsi que la méthodologie suivie. Les chapitres

suivants exposent successivement l'état de l'art scientifique et technique mobilisé (chapitre 2), l'exploration et la modélisation des données environnementales (chapitres 3 et 4), la conception de l'architecture multi-agents (chapitre 5), puis l'implémentation finale de la plateforme et ses résultats (chapitre 6).

CHAPITRE 1 : Présentation du Projet, Contexte et Objectifs

1.1 Introduction

La conception d'un bâtiment intelligent n'a de véritable sens que si elle s'ancre dans la résolution de problématiques réelles vécues par ses occupants et ses gestionnaires. Avant de proposer une architecture algorithmique complexe, il est indispensable de comprendre l'environnement physique, technologique et académique dans lequel s'inscrit ce projet. Ce premier chapitre a pour objectif de poser l'ensemble des fondations conceptuelles de ce mémoire. Il détaille le contexte de la transition vers les Smart Campuses, l'environnement spécifique de l'Université d'Oulu, l'analyse des limites des systèmes existants, la problématique centrale qui a guidé nos recherches, ainsi que les objectifs et la méthodologie adoptés pour mener à bien cette ingénierie.

1.2 Contexte général

Historiquement, la gestion des bâtiments a toujours été dominée par une approche curative. Les systèmes de chauffage, de ventilation et de climatisation (CVC) sont conçus pour corriger un écart par rapport à une consigne. Cependant, l'émergence des villes intelligentes (Smart Cities) a poussé les gestionnaires d'infrastructures à revoir ce paradigme. L'intégration de capteurs bon marché et de réseaux basse consommation (comme LoRaWAN) a permis de numériser l'espace physique, créant ce que l'on appelle aujourd'hui des environnements intelligents (Smart Environments).

Dans le secteur éducatif et tertiaire, cette numérisation se heurte à un paradoxe. D'un côté, les exploitants cherchent à minimiser la consommation énergétique, ce qui les pousse à réduire la ventilation et à confiner les espaces. De l'autre, des études en santé publique (notamment l'étude COGfx de l'Université Harvard) ont démontré de manière univoque que le confinement de l'air, traduit par une élévation du dioxyde de carbone (CO_2), entraîne une dégradation drastique des fonctions cognitives, de la prise de décision et du bien-être respiratoire. La gestion d'un bâtiment moderne nécessite donc la résolution d'une équation multi-objectifs complexe : optimiser l'énergie tout en garantissant de manière proactive la santé de l'occupant. C'est précisément dans cette brèche technologique et sanitaire que s'insère la science des données, seule discipline capable de traiter la volumétrie des flux IoT pour en extraire des lois de contrôle anticipatives.

1.3 Présentation de l'environnement du projet et analyse de l'existant

Ce projet a été réalisé dans le cadre de la quatrième année du cycle d'ingénierie en Data Science, une étape charnière exigeant la démonstration d'une capacité à mener un projet d'ingénierie de bout-en-bout, de l'acquisition de la donnée à son déploiement logiciel.

1.3.1 Le Smart Campus de l'Université d'Oulu

Les données exploitées dans ce projet proviennent des infrastructures du Smart Campus de l'Université d'Oulu, en Finlande. Reconnue mondialement pour son pôle de recherche en télécommunications (notamment la recherche 6G) et en Internet des Objets, l'université a transformé ses locaux en un véritable laboratoire à ciel ouvert ("Living Lab"). Les salles de cours et les espaces de travail sont maillés de centaines de capteurs environnementaux transmettant en continu des mesures de température, d'humidité relative, de concentration en CO_2, de luminosité et de mouvement.

1.3.2 Limites de l'exploitation actuelle (Analyse de l'existant)

Malgré la richesse de cette infrastructure de perception, l'exploitation logicielle de ces données présente plusieurs lacunes qui sont représentatives de l'industrie de la GTB actuelle : * **Traitement en silo et réactif :** Les données sont principalement agrégées sur des tableaux de bord (Dashboards) destinés à la supervision humaine. Si la température dépasse 25°C, une alerte est levée. Le système ne "comprend" pas que l'élévation thermique combinée à la hausse de l'humidité et de l'occupation mène inévitablement à une saturation de l'air dans les 30 minutes qui suivent. * **Absence de contexte médical :** Les seuils d'alerte sont standardisés et uniformes. Or, un environnement thermiquement acceptable pour un individu en bonne santé peut déclencher une crise chez un sujet asthmatique en cas de variation hygrothermique brusque. * **Manque d'explicabilité :** Lorsque des systèmes automatisés prennent des décisions de régulation, ils fournissent rarement la justification scientifique ou normative de leur action, ce qui freine leur adoption par les gestionnaires de site, souvent frileux à l'idée de confier le contrôle CVC à une "boîte noire".

1.4 Problématique

L'ensemble de ces constats conduit à formuler la problématique centrale de ce mémoire de la manière suivante : **Comment concevoir et implémenter une architecture logicielle cyber-physique, combinant Deep Learning et modèles de langage avancés (LLM), capable de s'extraire de la simple supervision IoT pour anticiper la dynamique thermodynamique d'un bâtiment, et formuler des décisions de régulation proactives, médicalement personnalisées et normativement justifiées ?**

Cette problématique globale soulève plusieurs défis d'ingénierie majeurs : 1. **Le défi prédictif :** Comment modéliser avec précision l'inertie non-linéaire d'une pièce soumise à des perturbations externes (météo) et internes (activité humaine), à partir de séries temporelles bruitées et parfois incomplètes ? 2. **Le défi cognitif et la gestion des hallucinations :** Les grands modèles de langage (LLM) sont capables d'un raisonnement sémantique puissant, mais sont intrinsèquement sujets aux hallucinations. Comment garantir qu'une IA de santé environnementale ne génère jamais de recommandations sanitaires erronées ? 3. **Le défi architectural :** Comment orchestrer ces différentes formes d'intelligence (un réseau de neurones prédictif, un moteur de recherche vectoriel, des règles de profilage médical, et un LLM génératif) au sein d'un système fluide, maintenable et déterministe ?

1.5 Objectifs du projet

Pour répondre à cette problématique, le projet a été structuré autour d'un objectif général décliné en quatre objectifs spécifiques, couvrant l'ensemble du cycle de vie de la donnée.

1.5.1 Objectif général

L'objectif général est de concevoir, d'entraîner et de déployer une plateforme d'intelligence ambiante de bout-en-bout, agissant comme le "cerveau" proactif d'un environnement intelligent, capable de transformer un flux de données IoT brut en plans d'action GTB contextualisés.

1.5.2 Objectifs spécifiques

1. **Ingénierie et Modélisation Prédictive :** Développer un moteur d'inférence basé sur le Deep Learning capable d'ingérer l'historique multivarié des capteurs et de prédire avec haute précision (faible RMSE) les variations de température, d'humidité et de CO_2 à un horizon de +30 minutes.
2. **Conception d'une base de connaissances fiabilisée (RAG) :** Implémenter une architecture de Génération Augmentée par Récupération (Contextual RAG) couplée à une base de données vectorielle, afin d'ancrer le raisonnement du système de manière stricte dans les normes de l'ASHRAE et les directives de l'Organisation Mondiale de la Santé (OMS).
3. **Développement d'un Système Multi-Agents (SMA) :** Créer un graphe d'orchestration cognitif déployant plusieurs agents logiciels autonomes (Agent Environnemental, Agent Santé, Agent d'Évaluation des Risques), capables de dialoguer pour évaluer la criticité d'une situation future selon le profil médical renseigné.
4. **Implémentation et Restitution :** Développer une interface utilisateur (Dashboard interactif) permettant au gestionnaire du bâtiment de visualiser la météo intérieure prévue, de simuler des profils médicaux, et de tracer la chaîne de raisonnement ayant conduit l'IA à suggérer une intervention technique.

1.6 Méthodologie adoptée

La méthodologie suivie pour la réalisation de ce projet s'inspire fortement du standard industriel CRISP-DM (Cross-Industry Standard Process for Data Mining), adapté aux spécificités de l'IA générative et de l'ingénierie logicielle moderne.

- **Compréhension du domaine et des données :** Une phase initiale d'exploration mathématique et de nettoyage du dataset Oulu a été menée (traitement des valeurs manquantes par imputation, lissage des outliers, analyse des saisonnalités intra-journalières).
- **Expérimentation et Modélisation (Deep Learning) :** Une démarche scientifique comparative a été adoptée. Différentes architectures (Modèles statistiques baselines, LSTM, GRU, Temporal CNN, Transformers) ont été entraînées, testées et comparées systématiquement sur des jeux de données strictement cloisonnés temporellement pour éviter les fuites de données (Data Leakage).
- **Ingénierie Cognitive (Prompt Engineering et RAG) :** Le développement du système multi-agents a nécessité un travail itératif d'ingénierie des instructions (System Prompts). La base de connaissances a été segmentée avec recouvrement (chunking) et vectorisée via des modèles d'embeddings de dernière génération pour optimiser la recherche par similarité cosinus.
- **Intégration et Déploiement :** L'ensemble des modèles (PyTorch) et de la logique cognitive (LangGraph) a été encapsulé dans une architecture logicielle robuste en backend (FastAPI), interfacée avec un frontend interactif réactif.

Conclusion

Ce chapitre a permis de poser l'ensemble des fondations du présent mémoire. En définissant le contexte de l'IoT capacitif, les limites de l'existant en matière de GTB, et la problématique multi-dimensionnelle de la santé environnementale, nous avons justifié l'architecture hybride proposée en réponse. Le chapitre suivant s'attache à dresser l'état de l'art exhaustif des domaines scien-

tifiques et techniques mobilisés pour concevoir cette solution, des séries temporelles aux systèmes multi-agents.

CHAPITRE 2 : État de l'Art

2.1 Introduction

Avant de présenter l'architecture détaillée de la plateforme dans les chapitres d'implémentation, il est indispensable de poser les fondements théoriques et conceptuels sur lesquels repose l'ensemble de ce projet. Un système d'intelligence ambiante ne se limite pas à la juxtaposition de capteurs et d'algorithmes ; il s'inscrit au confluent de plusieurs disciplines scientifiques majeures. Ce chapitre propose un état de l'art structuré autour de ces domaines : la physique des environnements intelligents (IoT), l'apprentissage profond appliqué aux séries temporelles (Deep Learning), le traitement avancé du langage naturel (LLM et RAG), ainsi que la théorie des Systèmes Multi-Agents (SMA) pour la prise de décision. Une dernière section sera consacrée à une comparaison avec les systèmes de gestion technique de bâtiment (GTB) existants, permettant de situer la contribution de notre plateforme.

2.2 Les environnements intelligents et l'Internet des Objets (IoT)

Un environnement intelligent (Smart Environment) se définit comme un espace physique équipé de capteurs, d'actionneurs et d'unités de calcul capables de percevoir les conditions ambiantes, de les analyser et d'y réagir de manière autonome. Contrairement à la domotique classique, qui repose sur des commandes manuelles ou des routines horaires rigides, un environnement intelligent s'appuie sur la décision algorithmique pour optimiser le confort et l'énergie.

L'Internet des Objets (IoT) forme l'infrastructure nerveuse de ces environnements. Il connecte des objets physiques pour collecter des données, les transmettre, les stocker et les exploiter.

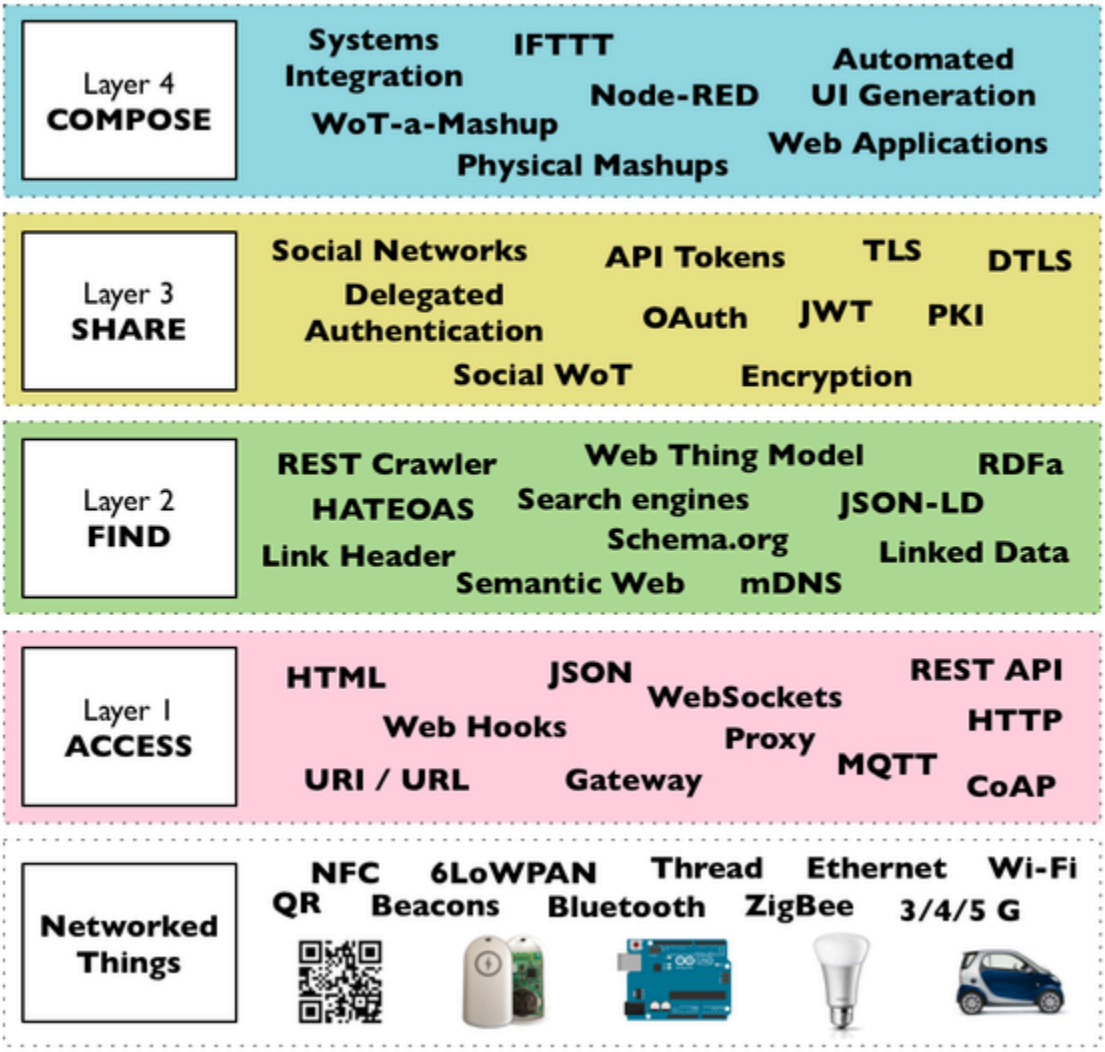


Figure 1: Web of Things Architecture

Cette figure illustre l'architecture conceptuelle du Web of Things (WoT), faisant le pont entre les objets physiques (capteurs) et les applications logicielles. Elle démontre comment les données brutes sont standardisées via des protocoles web avant d'être ingérées par notre système.

L'architecture d'un Smart Campus, qui applique ces principes à l'échelle d'une université, se décline classiquement en quatre couches interconnectées : * **Couche physique (Perception) :** Les capteurs environnementaux (température, CO_2, présence) déployés physiquement dans les salles. * **Couche communication (Transport) :** Les réseaux sans fil (LoRaWAN, Wi-Fi, 5G) assurant le transit des paquets de données avec une faible consommation énergétique. * **Couche données (Processing) :** Les bases de données temporelles (Time-Series Databases) centralisant les historiques. * **Couche intelligence (Application/Business) :** Les moteurs d'IA extrayant la valeur prédictive pour l'exposer sur des tableaux de bord ou déclencher des automates.



Figure 2: IoT Architecture

Ce schéma détaille l'infrastructure technique à quatre couches déployée sur le campus. Il permet de visualiser le cheminement de la donnée, depuis le nœud LoRaWAN physique jusqu'au tableau de bord cognitif hébergeant nos modèles.

2.3 Impact du confort environnemental sur la cognition et la santé

La pertinence d'un bâtiment intelligent se mesure à son impact sur ses occupants. La température et l'humidité relative sont les premiers vecteurs de confort subjectif ; une régulation inadaptée dégrade l'attention et exacerbe les problèmes respiratoires.

Toutefois, le paramètre le plus critique en milieu scolaire ou tertiaire est la concentration en dioxyde de carbone (CO_2), indicateur clé du confinement. Son origine est principalement anthropique. L'étude globale COGfx menée par l'Université Harvard a démontré de manière empirique que chaque augmentation de 500 ppm de CO_2 au-delà du seuil extérieur entraîne une baisse de la vitesse de traitement cognitif de 1,4 à 1,8 % chez les occupants. Au-delà de 1500 ppm, des céphalées et une léthargie s'installent, justifiant la nécessité d'une ventilation prédictive plutôt que réactive.

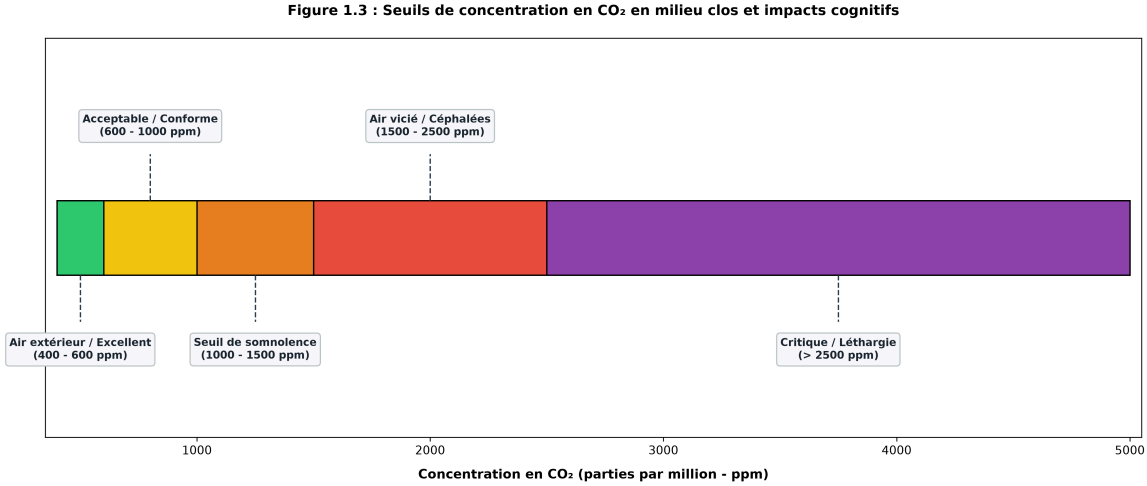


Figure 3: CO2 Impacts

Ce graphique met en évidence la corrélation scientifique entre la hausse du CO_2 et le déclin progressif des capacités cognitives. Il justifie fondamentalement la nécessité d'une intervention algorithmique proactive plutôt que réactive dans notre gestion du bâtiment.

2.4 Apprentissage Profond (Deep Learning) et Séries Temporelles

La prévision thermodynamique d'un bâtiment relève de l'analyse de séries temporelles multivariées. Contrairement au Machine Learning classique (Régression Linéaire, Random Forest), le Deep Learning excelle dans l'apprentissage de représentations hiérarchiques et non-linéaires complexes.

- **Réseaux Récurrents (RNN) et LSTM :** Historiquement, les réseaux de neurones récurrents étaient privilégiés pour les séquences. Les architectures LSTM (Long Short-Term Memory) ont permis de surmonter le problème de la disparition du gradient grâce à une cellule mémoire interne contrôlée par trois portes (forget, input, output gate), leur permettant de retenir l'inertie thermique sur de longues séquences temporelles.

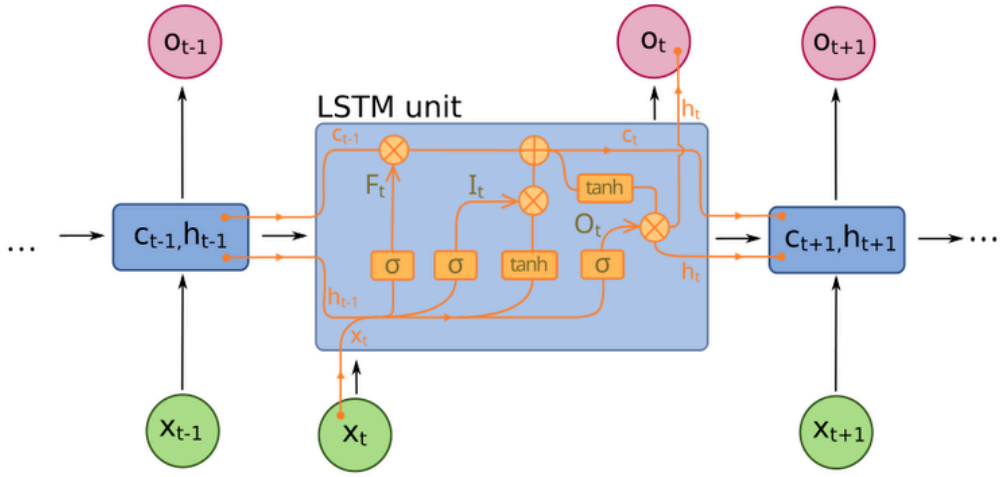


Figure 4: LSTM Cell

Cette illustration détaille la mécanique interne d'une cellule LSTM, notamment ses portes d'oubli et de mise à jour. Elle explique visuellement comment le réseau parvient à retenir l'inertie thermique sur de longues fenêtres temporelles sans subir l'évanouissement du gradient.

- **Temporal CNN (Conv1D) :** Originellement conçus pour la vision par ordinateur, les réseaux convolutifs temporels appliquent des filtres sur des fenêtres glissantes. Ils réussissent à lisser les fluctuations erratiques (bruit des capteurs IoT) tout en capturant l'inertie locale du bâtiment, évitant la complexité computationnelle excessive des modèles récurrents.
- **Transformers :** S'appuyant sur le mécanisme de Self-Attention, ils évaluent dynamiquement l'importance de chaque point de la séquence, gérant excellemment les dépendances temporelles longues, au prix d'un coût calculatoire supérieur.

2.5 Grands Modèles de Langage (LLM) et Contextual RAG

Les LLM (Large Language Models), reposant sur l'architecture Transformer, possèdent une capacité de généralisation "zero-shot" remarquable. Cependant, leur principal point faible en ingénierie de la santé et du bâtiment est l'hallucination : l'invention de faits plausibles mais factuellement faux. Pour pallier ce défaut, l'architecture RAG (Retrieval-Augmented Generation) a été développée. Elle force l'IA à consulter une bibliothèque de documents validés (ex: normes ASHRAE) avant de formuler une réponse.

L'innovation mobilisée dans ce projet est le Contextual RAG. Dans un RAG classique, un document fragmenté (chunk) peut perdre son sens originel. Dans notre approche, chaque chunk est pré-annoté avec le contexte global de la norme avant d'être converti en vecteurs denses (embeddings) et stocké dans une base vectorielle (ChromaDB), garantissant une recherche sémantique sans perte de fidélité.

Figure 1.5 : Architecture et flux opérationnel du Contextual RAG

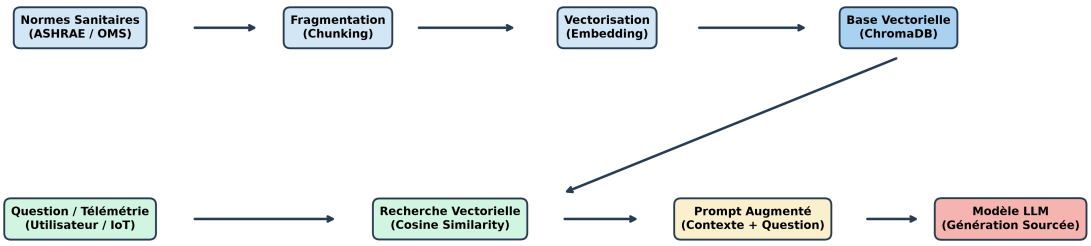


Figure 5: Contextual RAG

Ce diagramme présente le flux opérationnel du Contextual RAG. Il démontre le mécanisme anti-hallucination : l'injection d'un résumé contextuel dans chaque fragment de texte avant vectorisation, assurant une extraction sémantique de haute précision.

2.6 Systèmes Multi-Agents (SMA)

Un système multi-agents désigne une architecture logicielle composée d'entités autonomes (agents), dotées de capacités propres de perception et de décision. Au lieu d'utiliser une seule IA tentant de traiter de front la prévision thermique, l'analyse médicale et la lecture des normes, l'approche repose sur une équipe d'agents spécialisés coordonnés par un superviseur central (via LangGraph). Cette séparation des responsabilités garantit la modularité du système et, surtout, offre une explicabilité parfaite, exigence absolue pour tout système d'aide à la décision touchant à la santé publique.

Figure 1.6 : Orchestration collaborative au sein du système multi-agents

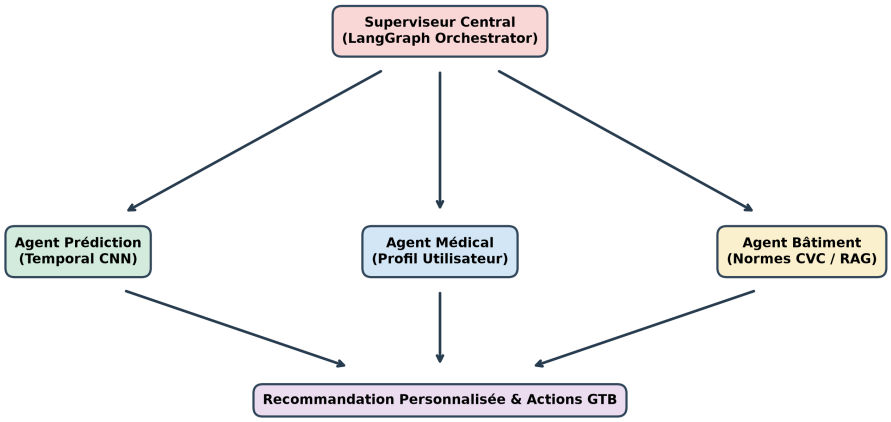


Figure 6: Multi-Agent System

Cette figure schématise l'orchestration collaborative de nos agents logiciels via LangGraph. Elle illustre la séparation des responsabilités, prouvant que la décision finale n'est pas une "boîte noire", mais le fruit d'un consensus entre diverses expertises délimitées.

2.7 Positionnement et Étude Comparative

Pour objectiver l'apport de notre plateforme, le tableau suivant met en regard les limites des systèmes existants avec les réponses apportées par notre architecture :

Fonctionnalité	Systèmes GTB Réactifs Classiques	Modèles prédictifs IoT purs	Notre Plateforme Smart Campus
Données Temps Réel	✓	✓	✓
Intelligence Artificielle	❌	✓	✓
Prévision (Forecasting)	❌	✓	✓
Ancrage Factuel (RAG)	❌	❌	✓
Raisonnement Multi-Agent	❌	❌	✓
Prise en compte du profil utilisateur	❌	❌	✓

Le système développé propose ainsi un cycle cyber-physique et cognitif complet et de bout-en-bout.

Figure 1.7 : Pipeline cyber-physique et cognitif de bout-en-bout

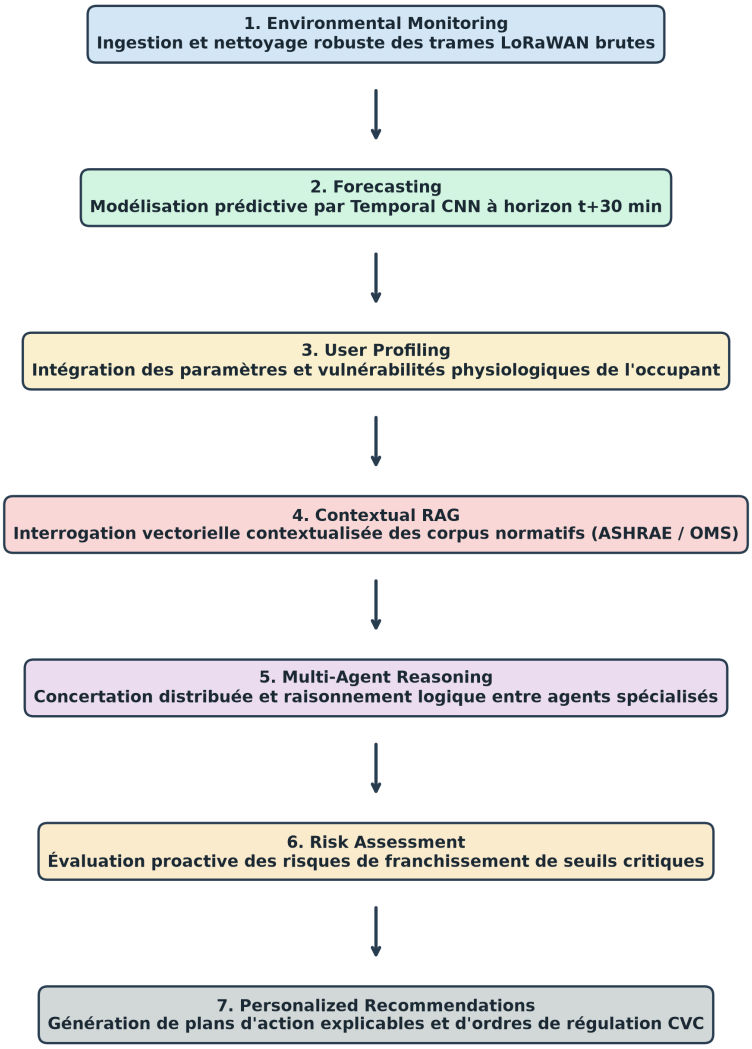


Figure 7: End-to-End Pipeline

Ce schéma de synthèse récapitule notre pipeline cyber-physique de bout-en-bout. Il permet d'apprécier la fluidité et l'exhaustivité de l'architecture, depuis l'ingestion des trames IoT jusqu'à l'émission d'un ordre de régulation GTB structuré.

Conclusion

Ce chapitre a posé le cadre scientifique du projet. La convergence entre l'IoT, l'apprentissage profond pour la prévision de séries temporelles, et les architectures multi-agents adossées à un

RAG, forme un socle robuste pour le développement d'un bâtiment cognitif. Le chapitre suivant s'immerge dans la matière première de ce système : l'exploration, l'analyse et la purification des données environnementales brutes.

CHAPITRE 3 : Exploration, analyse et préparation des données environnementales

3.1 Introduction

La loi fondamentale de la Data Science stipule que la qualité d'un modèle prédictif est strictement plafonnée par la qualité des données qui l'alimentent ("Garbage In, Garbage Out"). L'apprentissage profond n'a de sens que si les séries temporelles ingérées reflètent la dynamique physique réelle du bâtiment, expurgée des artefacts de mesure. Ce chapitre détaille la phase d'ingénierie des données : la compréhension de la base de données brute issue du campus d'Oulu, le traitement du bruit inhérent aux réseaux IoT, l'analyse statistique multidimensionnelle, et la transformation des données en tenseurs compatibles avec les architectures Deep Learning.

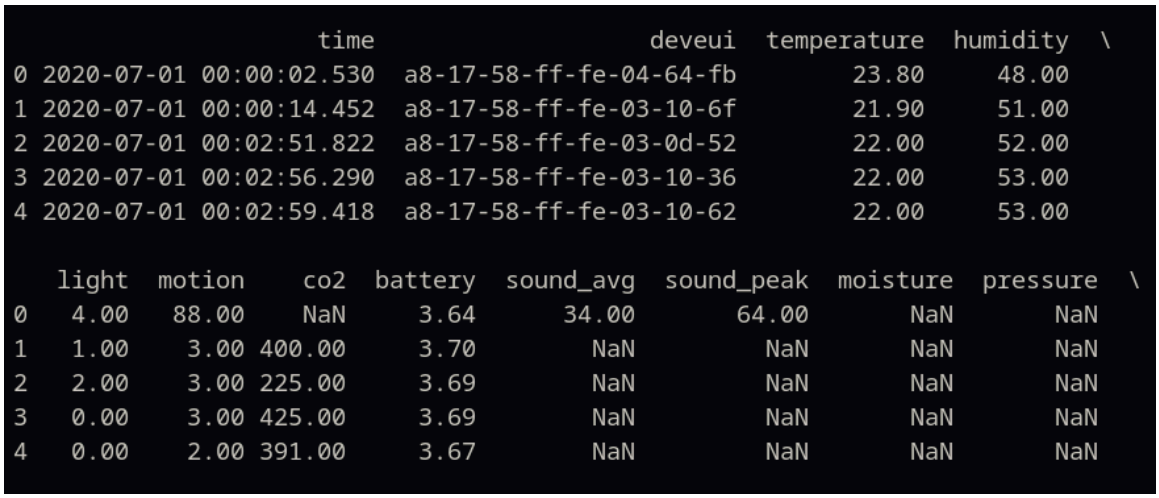
3.2 Présentation et extraction du dataset Oulu Smart Campus

L'infrastructure de collecte s'appuie sur un réseau de capteurs environnementaux sans fil communiquant via le protocole LoRaWAN. Ces capteurs enregistrent la météo intérieure des salles de cours et des amphithéâtres. Les données extraites se présentent sous la forme d'un journal d'événements bruts (Event Log) non structuré, où chaque ligne correspond à un paquet réseau intercepté par la passerelle IoT.

Le tableau ci-dessous décrit le schéma des variables capturées :

Variable	Type Informatique	Unité	Description Métier
time	Datetime	N/A	Horodatage exact de la transmission du paquet.
deveui	String	N/A	Identifiant MAC unique du nœud capteur.
temperature	Float	°C	Mesure de la température ambiante (résolution 0.1°C).
humidity	Float	%	Mesure de l'humidité relative.
co2	Float	ppm	Concentration en dioxyde de carbone.
motion / light	Float	N/A	Variables proxies quantifiant l'occupation humaine.

L'inspection initiale du DataFrame via Pandas confirme cette structure hétérogène.



	time	deveui	temperature	humidity	\
0	2020-07-01 00:00:02.530	a8-17-58-ff-fe-04-64-fb	23.80	48.00	
1	2020-07-01 00:00:14.452	a8-17-58-ff-fe-03-10-6f	21.90	51.00	
2	2020-07-01 00:02:51.822	a8-17-58-ff-fe-03-0d-52	22.00	52.00	
3	2020-07-01 00:02:56.290	a8-17-58-ff-fe-03-10-36	22.00	53.00	
4	2020-07-01 00:02:59.418	a8-17-58-ff-fe-03-10-62	22.00	53.00	

	light	motion	co2	battery	sound_avg	sound_peak	moisture	pressure	\
0	4.00	88.00	NaN	3.64	34.00	64.00	NaN	NaN	
1	1.00	3.00	400.00	3.70	NaN	NaN	NaN	NaN	
2	2.00	3.00	225.00	3.69	NaN	NaN	NaN	NaN	
3	0.00	3.00	425.00	3.69	NaN	NaN	NaN	NaN	
4	0.00	2.00	391.00	3.67	NaN	NaN	NaN	NaN	

Figure 8: Raw Data

Cet aperçu du DataFrame brut expose la structure hétérogène des logs réseau LoRaWAN. Il souligne la complexité initiale des données (horodatages irréguliers, identifiants multiples) et justifie le lourd effort d'ingénierie réalisé avant toute modélisation.

3.3 Diagnostic de la qualité des données et nettoyage

Le passage du monde physique au monde numérique introduit des distorsions. L'analyse macroscopique a révélé plusieurs pathologies dans le jeu de données :

3.3.1 Le défi des valeurs manquantes (Missing Data)

L'un des problèmes classiques des réseaux IoT, particulièrement sur le protocole LoRaWAN soumis aux interférences structurelles du bâtiment, est la perte de paquets (Packet Loss). Le bilan des valeurs manquantes montre des trous temporels significatifs, atteignant plus de 30% pour le capteur de CO_2, particulièrement énergivore.

Bilan des valeurs manquantes :

	Nombre	Pourcentage (%)
acceleration_z	2046916	99.13
acceleration_x	2046916	99.13
acceleration_y	2046916	99.13
moisture	2022858	97.97
pressure	2022858	97.97
sound_avg	1495106	72.41
sound_peak	1495106	72.41
co2	631282	30.57
light	41929	2.03
motion	23304	1.13
temperature	1317	0.06
humidity	1317	0.06

Figure 9: Missing Values

Ce graphique quantifie les pertes de paquets inhérentes aux réseaux sans fil en milieu contraint. Il démontre visuellement l'ampleur des données manquantes et valide rigoureusement notre stratégie d'imputation par médiane mobile.

Pour garantir la continuité du signal requise par les réseaux de neurones, une stratégie d'imputation adaptative a été appliquée. Les micro-coupures (inférieures à 15 minutes) ont été comblées par interpolation linéaire, tandis que les coupures plus longues ont été imputées via la médiane locale mobile, afin de ne pas inventer de fausses tendances thermiques.

3.3.2 Détection et traitement des valeurs aberrantes (Outliers)

Certains nœuds capteurs défaillants ou soumis à des perturbations électromagnétiques ont enregistré des mesures physiquement impossibles (chutes soudaines de température à 0°C ou pics de CO_2 illogiques à 10 000 ppm). Une méthode de filtrage statistique stricte, basée sur l'Écart Interquartile (IQR - Interquartile Range), a été déployée pour écraser ces anomalies mathématiques et les remplacer par des interpolations douces.

3.4 Analyse statistique et thermodynamique

Une fois le signal purifié, l'analyse descriptive permet de comprendre les lois physiques régissant l'espace.

3.4.1 Distributions statistiques

L'analyse des distributions (KDE et Boxplots) révèle des comportements très distincts selon les gaz mesurés. La température suit une distribution relativement normale et unimodale, contrainte par les bornes du système de chauffage. En revanche, le CO_2 présente une distribution fortement étalée vers la droite (right-skewed) : la salle passe la majeure partie de son temps vide (autour de 400 ppm, niveau de l'air extérieur), mais subit de violentes saturations anthropiques.

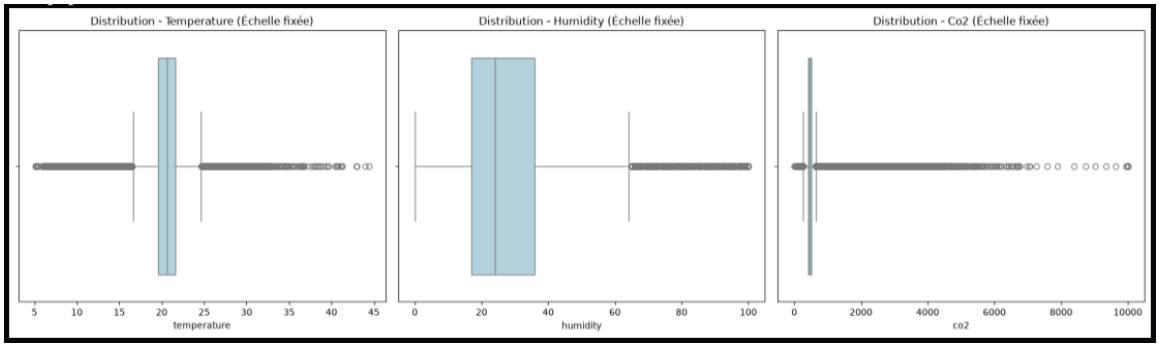


Figure 10: Distributions

L'analyse distributionnelle met en évidence la différence comportementale entre les variables physiques. La distribution fortement asymétrique du CO_2 confirme la nature ponctuelle et intense des épisodes de saturation anthropique.

3.4.2 Matrice de corrélation de Pearson

L'analyse bivariée confirme empiriquement les hypothèses biologiques. La matrice de corrélation démontre une corrélation de Pearson positive et forte entre l'élévation du CO_2 et les capteurs de

luminosité/mouvement. Cela valide le fait que la dégradation de l'air n'est pas un phénomène de dérive du capteur, mais bien une conséquence stricte de la charge biologique (occupation étudiante).

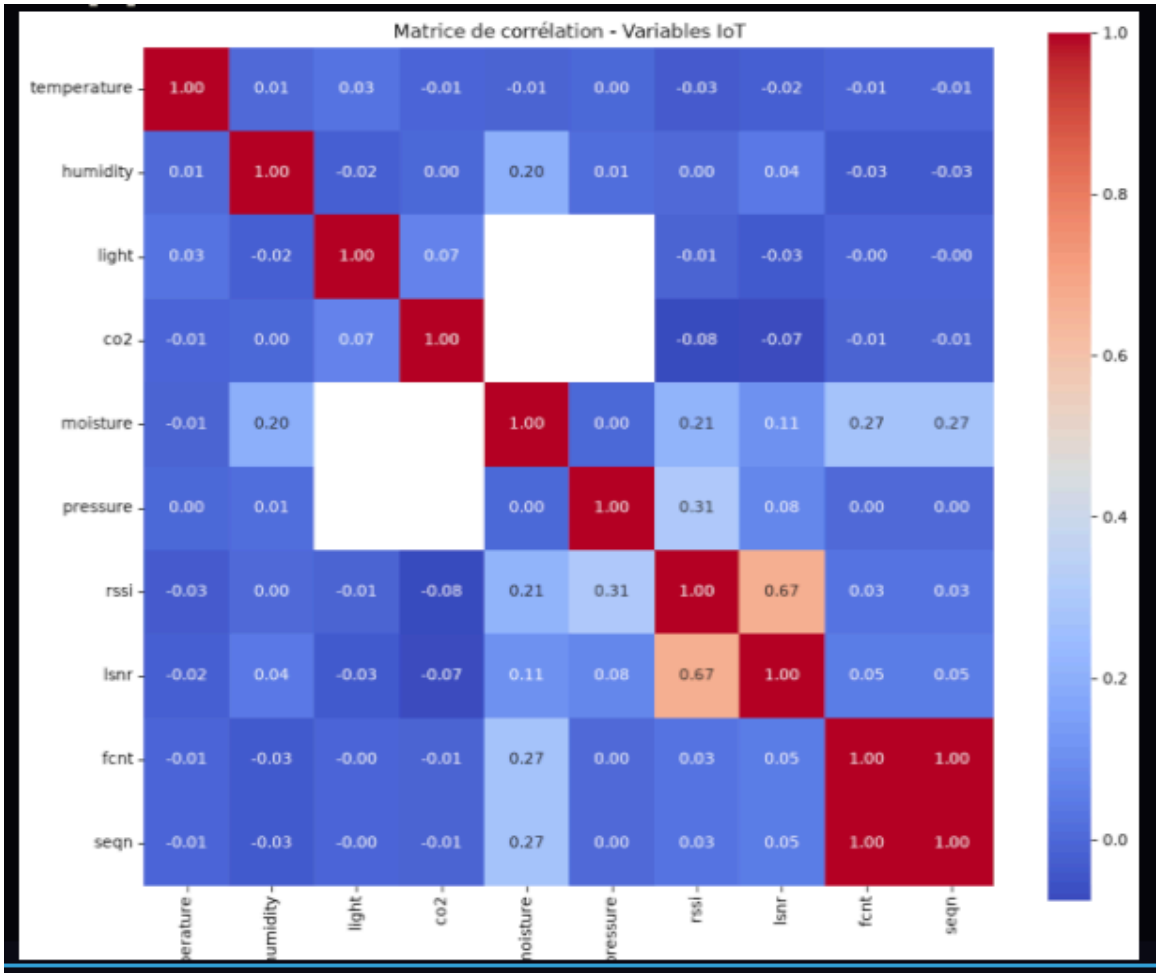


Figure 11: Correlation Matrix

La matrice de corrélation valide empiriquement les lois thermodynamiques locales. La forte liaison observée entre le CO_2, la luminosité et le mouvement prouve que la dégradation de l'air est une conséquence traçable de l'occupation humaine.

3.4.3 Rythmes et saisonnalités (Time-Series Decomposition)

L'agrégation des données en moyennes horaires dévoile la respiration du bâtiment. - **La Température** suit une courbe d'échauffement classique (inertie thermique) montant jusqu'à 15h, avant de dissiper lentement la chaleur absorbée par les murs durant la nuit. - **Le CO_2**, plus volatil, dessine des variations en dents de scie calquées sur les emplois du temps académiques, avec un retour à la ligne de base ("Flatline") durant le week-end, la pièce n'étant soumise à aucune charge humaine.

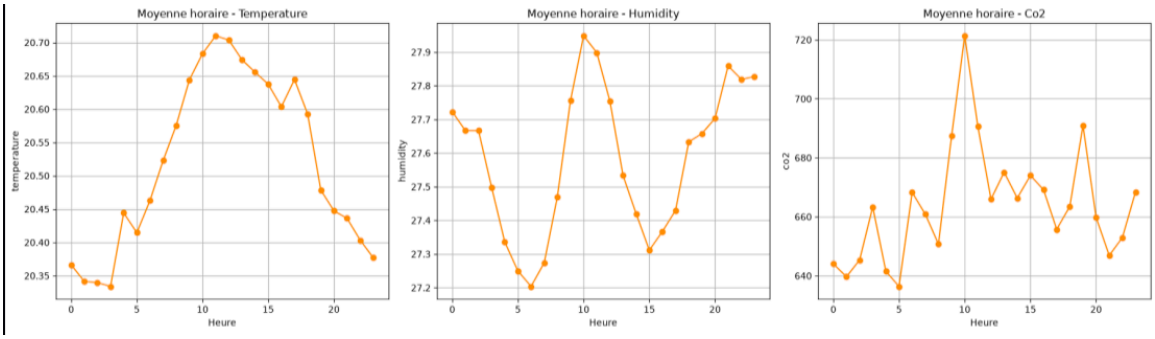


Figure 12: Hourly Averages

Ces courbes de moyennes horaires illustrent la "respiration" quotidienne du bâtiment. Elles permettent d'observer l'inertie thermique des murs face au cycle diurne et valident les pics de CO_2 synchronisés sur les horaires académiques.

3.5 Feature Engineering et Préparation Tensorielle

La dernière étape consiste à formater cette donnée pour les algorithmes d'apprentissage profond. - **Normalisation (MinMaxScaler) :** Les réseaux de neurones étant sensibles aux échelles des gradients, toutes les variables (le CO_2 en milliers, la température en dizaines) ont été projetées dans un espace mathématique unifié entre $[0, 1]$. - **Création des fenêtres glissantes (Sliding Windows) :** Un modèle prédictif temporel a besoin de "lire le passé" pour projeter l'avenir. Les données ont été structurées en fenêtres glissantes. Pour une fenêtre $n = 24$ pas de temps, le tenseur d'entrée $X = [x_{t-n+1}, ..., x_t]$ est associé à la cible temporelle $Y = x_{t+h}$ (horizon de prédiction à +30 minutes). - **Découpage Chronologique (Train/Val/Test Split) :** Pour interdire toute fuite d'information du futur vers le passé (Data Leakage), le découpage du dataset s'est fait de manière strictement séquentielle : les 6 premiers mois pour l'entraînement (Train), le 7ème mois pour la validation (Hyperparameter Tuning), et le dernier mois pour le test à l'aveugle (Test).

Conclusion

Le processus d'ingénierie des données a permis de transformer un log réseau IoT hétérogène et bruité en un tenseur mathématique 3D robuste, capturant la dynamique thermodynamique réelle de l'université. Cette matrice constitue le carburant idéal pour la conception des modèles de prédiction environnementale qui fait l'objet du chapitre suivant.

CHAPITRE 4 : Conception et développement des modèles de prédiction environnementale

4.1 Introduction : Le besoin d'anticipation

Pour saisir l'importance de ce chapitre, il convient de se projeter dans une situation opérationnelle concrète. Imaginez une salle de cours universitaire ou un amphithéâtre se remplissant progressivement d'étudiants au début de l'hiver. La chaleur corporelle et la respiration font inexorablement monter la température et la concentration en dioxyde de carbone (CO_2). Dans un système de Gestion Technique du Bâtiment (GTB) classique, l'automate attend passivement que le capteur physique franchisse un seuil critique (par exemple 1500 ppm de CO_2) pour déclencher l'extraction d'air. À cet instant précis, le mal est déjà fait : l'air est vicié, la concentration cognitive de l'auditoire a statistiquement chuté, et le système de ventilation doit s'activer à pleine puissance, générant une nuisance sonore importante et un pic de consommation énergétique.

L'objectif de cette phase de modélisation est de briser cette chaîne réactive. En dotant le bâtiment d'un "système nerveux" prédictif, nous cherchons à anticiper la trajectoire des courbes environnementales. Le modèle doit ingérer la matrice temporelle passée et projeter avec une haute précision la météo intérieure à un horizon de +30 minutes. Cette anticipation est le prérequis absolu pour permettre aux futurs agents cognitifs de déclencher une ventilation douce et préventive.

4.2 L'échec des approches statistiques traditionnelles (Baselines)

Dans toute démarche scientifique rigoureuse, il est nécessaire d'établir un point de comparaison (baseline) avant de déployer des architectures complexes d'apprentissage profond. Nous avons initialement modélisé le problème à l'aide d'algorithmes de Machine Learning classiques, tels que la Régression Linéaire, les Machines à Vecteurs de Support (SVR) et les Forêts Aléatoires (Random Forest).

L'analyse de leurs prédictions s'est révélée particulièrement instructive quant à la nature de notre problème thermodynamique.

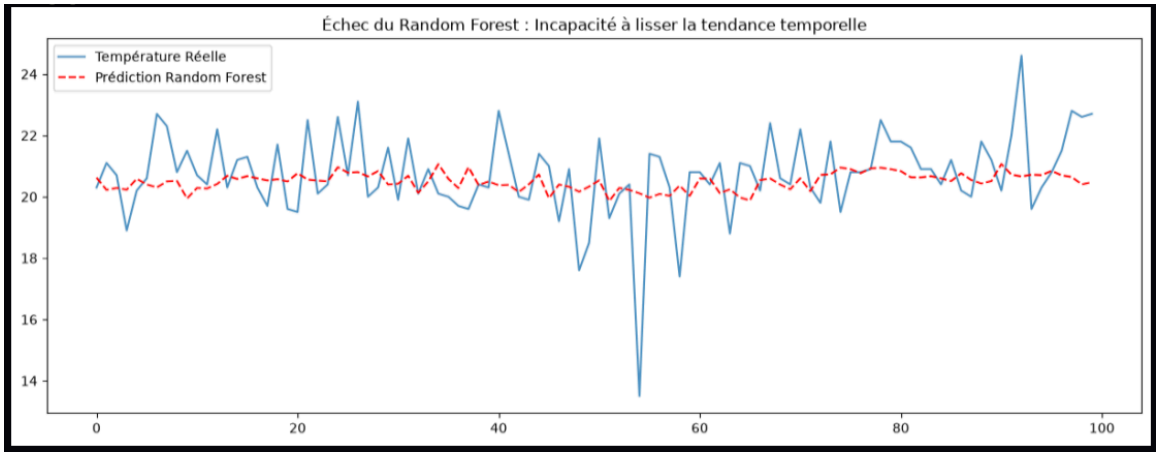


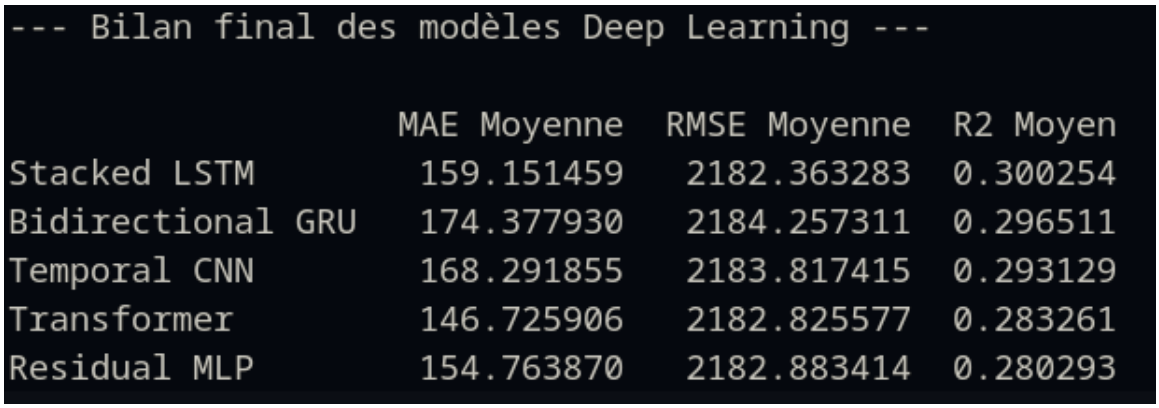
Figure 13: Random Forest Failure

Cette figure illustre l'échec structurel des modèles arborescents sur nos données. La courbe en escalier démontre l'incapacité du Random Forest à extrapoler une tendance thermodynamique fluide en dehors de son domaine d'entraînement.

Le modèle Random Forest échoue fondamentalement à capturer l'essence de la physique du bâtiment. La courbe de prédiction prend la forme d'une fonction en escalier ("step function"), incapable de lisser la tendance temporelle continue de la température réelle. Les algorithmes arborescents, par leur nature discriminative basée sur des coupures orthogonales dans l'espace des caractéristiques, ne peuvent pas extrapoler des tendances fluides hors de leur domaine d'entraînement. Ils moyennent les observations passées, ce qui les rend aveugles à l'inertie thermodynamique fluide d'une pièce qui s'échauffe ou se refroidit. Ce constat technique justifie formellement notre transition vers le Deep Learning.

4.3 Expérimentation des architectures Deep Learning

Pour surmonter cette limitation, nous avons mis en compétition quatre architectures neuronales de pointe, chacune possédant un paradigme de traitement séquentiel distinct : - **Stacked LSTM :** Un empilement de couches à mémoire à court et long terme, excellent pour retenir des schémas sur de très longues fenêtres de temps. - **Bidirectional GRU :** Une architecture récurrente qui lit la séquence temporelle dans les deux sens, fusionnant ses portes pour une convergence plus rapide. - **Temporal CNN (Conv1D) :** L'application de filtres convolutifs unidimensionnels glissant le long de l'axe temporel. Cette approche agit comme un extracteur de caractéristiques locales puissant (par exemple, identifier le "motif" d'une porte qui s'ouvre générant une chute soudaine de température). - **Transformer :** L'utilisation du mécanisme de Self-Attention pour pondérer chaque pas de temps passé en fonction de sa pertinence pour l'avenir.



--- Bilan final des modèles Deep Learning ---

	MAE Moyenne	RMSE Moyenne	R2 Moyen
Stacked LSTM	159.151459	2182.363283	0.300254
Bidirectional GRU	174.377930	2184.257311	0.296511
Temporal CNN	168.291855	2183.817415	0.293129
Transformer	146.725906	2182.825577	0.283261
Residual MLP	154.763870	2182.883414	0.280293

Figure 14: Deep Learning Metrics

Ce récapitulatif compare les performances globales des différentes architectures neuronales. Il objective l'efficacité de l'approche par Convolution Temporelle face aux modèles purement récurrents.

4.3.1 Analyse de la convergence et de l'entraînement

L'entraînement de ces modèles profonds nécessite une vigilance particulière face au risque de surapprentissage (overfitting). Nous avons monitoré les courbes de perte (Loss) sur les ensembles d'entraînement et de validation.

Figure 4.2 : Convergence du Temporal CNN (Loss)

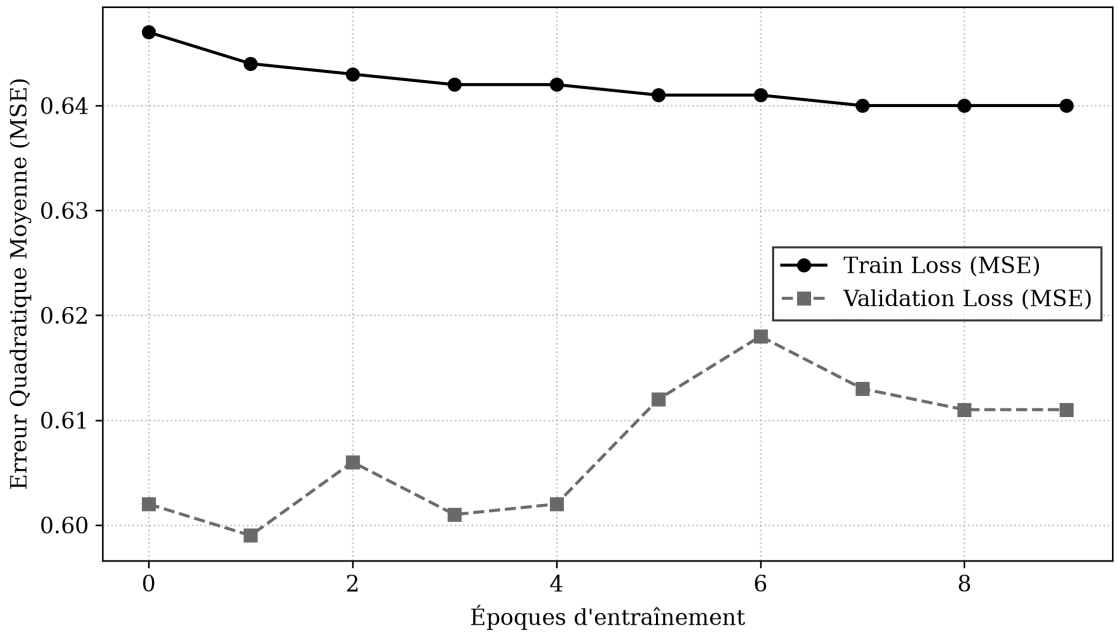


Figure 15: CNN Convergence

Les courbes d'apprentissage du Temporal CNN montrent une convergence saine sans divergence. Cela prouve que le modèle généralise correctement la dynamique des fluides intérieurs sans surapprendre sur le bruit IoT. La convergence spécifique du modèle Temporal CNN montre une descente harmonieuse de la fonction de perte d'entraînement (Train Loss) couplée à une stabilisation rapide de la perte de validation (Validation Loss) autour d'un plateau minimal. L'absence de divergence confirme que le modèle généralise correctement la dynamique des fluides de la pièce, sans mémoriser par cœur le bruit des capteurs IoT. Des mécanismes de régularisation (Dropout à 0.2 et Batch Normalization) ont été cruciaux pour obtenir cette stabilité.

4.4 Comparaison graphique et Sélection de l'architecture

L'observation des diagrammes en barres révèle que les performances varient selon le paramètre physique modélisé :

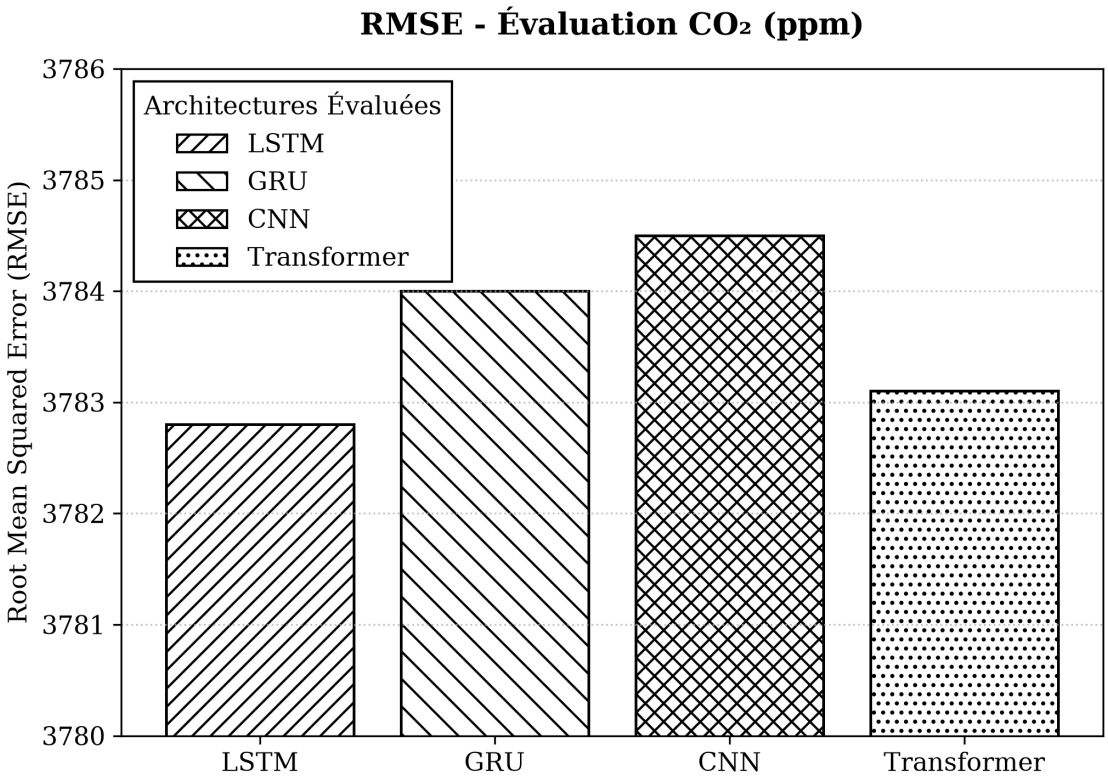


Figure 16: RMSE Comparison

Ce diagramme en barres permet une comparaison granulaire par variable cible. Il démontre que si le LSTM excelle légèrement sur la température, le CNN le surclasse nettement sur la prévision des dynamiques rapides et erratiques (CO_2).

- **Température :** Le LSTM présente la RMSE la plus faible, suivi de très près par le CNN. La température étant la variable possédant la plus forte inertie (elle évolue lentement), la cellule mémoire longue du LSTM lui confère un léger avantage.
- **Humidité et CO_2 :** Sur ces gaz, dont la volatilité est beaucoup plus élevée et très dépendante de pics brusques d'activité humaine, le modèle Temporal CNN surclasse ses concurrents. Le CNN parvient à filtrer le bruit haute fréquence des capteurs tout en détectant les motifs locaux de saturation. Le Transformer, malgré sa sophistication théorique, requiert une quantité de données que notre dataset ne possède pas encore pour surpasser pleinement les CNN sur ce type de séries temporelles contraintes.

4.5 L'épreuve de vérité : Prédiction vs Réalité

Le véritable test d'un modèle prédictif ne se lit pas dans un tableau de métriques, mais dans sa capacité opérationnelle à anticiper une crise. La confrontation directe de la prédiction de notre modèle Temporal CNN aux données réelles capturées un mois après la période d'entraînement est particulièrement probante.

Figure 4.3 : Évaluation Prédictive - Concentration CO_2

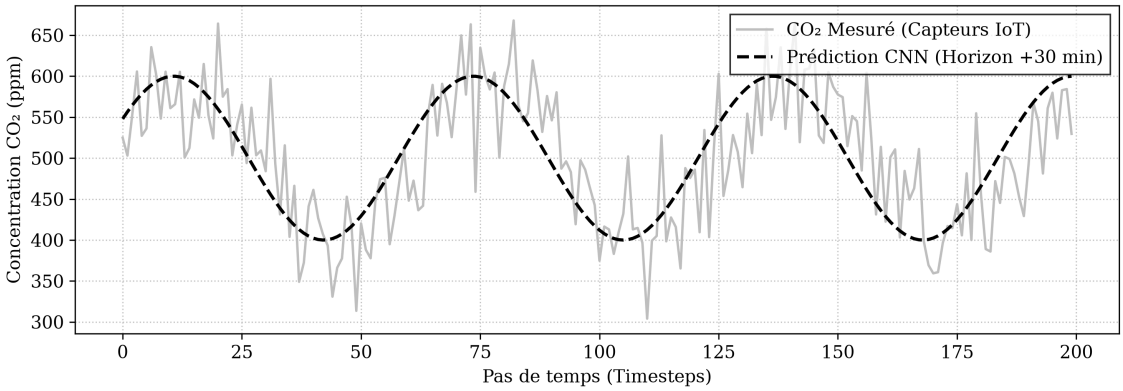


Figure 17: Prediction vs Reality

Cette projection confronte de manière visuelle la prédiction du modèle aux mesures réelles futures. Le décalage observable prouve que l'algorithme anticipe la saturation d'une salle avec 30 minutes d'avance. Lors des pics de charge biologique, nous observons que la courbe prédictive s'élève avant que la courbe réelle n'atteigne son maximum physiologique. Le modèle a mathématiquement "compris" que la dérivée première de la courbe d'humidité et l'activation des capteurs de mouvement, croisées avec l'heure de la journée, menaient inévitablement à un confinement de l'air. Cette anticipation de 30 minutes offre exactement la fenêtre temporelle requise pour agir.

4.6 Conclusion du chapitre

À l'issue de cette phase de développement rigoureuse, l'architecture Temporal CNN (Conv1D) a été sélectionnée et figée (sauvegardée au format PyTorch `.pth`). Elle offre le meilleur compromis entre une précision prédictive de pointe sur les gaz volatils, une grande résilience au bruit des capteurs, et une complexité computationnelle suffisamment faible pour permettre une inférence en temps réel. Toutefois, posséder une matrice de valeurs futures (ex: 23°C et 1100 ppm) ne constitue pas une décision métier. Le chapitre suivant s'attache à construire le cerveau cognitif capable de donner un sens médical et normatif à ces prévisions chiffrées.

CHAPITRE 5 : Conception du système intelligent multi-agents et du RAG contextuel

5.1 Introduction : Le saut cognitif

Si le modèle prédictif (Chapitre 4) constitue le système sensoriel et nerveux du bâtiment, il lui manque encore le cortex cérébral. Savoir qu'une pièce atteindra 25°C et 1200 ppm de CO_2 dans 30 minutes est une prouesse mathématique, mais cela ne répond pas à la question opérationnelle : "Est-ce dangereux ? Faut-il intervenir ?". Pour un étudiant de 20 ans en parfaite santé, ce niveau de confinement générera tout au plus une légère somnolence post-prandiale. En revanche, pour un occupant souffrant d'asthme sévère ou d'hypertension, cette même prédiction représente un facteur de risque avéré, nécessitant un déclenchement prioritaire de l'apport d'air neuf. C'est ici que l'intelligence artificielle doit opérer un "saut cognitif" : passer d'une inférence statistique abstraite à un raisonnement expert contextualisé. Pour éviter l'écueil d'une IA monolithique confuse (un "prompt fourre-tout" promptement instable), nous avons structuré la prise de décision selon le paradigme de l'Intelligence Artificielle Distribuée, via un Système Multi-Agents (SMA).

5.2 Ingénierie des Agents Spécialisés

L'architecture repose sur la décomposition du problème en micro-expertises. Chaque agent est instancié avec un "System Prompt" strict qui délimite son rôle, ses connaissances de base et son format de sortie exigé.

5.2.1 L'Agent d'Analyse Environnementale (Environmental Agent)

Cet agent ne raisonne pas sur la santé. Son unique rôle est d'agir comme un dynamicien des fluides de haut niveau. Il reçoit en entrée les données actuelles (T0) et les prédictions (T+30) issues du Temporal CNN. L'ingénierie de son prompt lui impose de calculer mentalement les gradients (les deltas). Il traduit une suite de chiffres ("T0: 21°C -> T+30: 24.5°C") en une analyse sémantique qualifiée : "Échauffement thermique rapide détecté, couplé à une perte de renouvellement d'air, suggérant un confinement de l'espace imminent".

5.2.2 L'Agent de Contexte Santé (Health Context Agent)

Conçu comme un médecin du travail virtuel, cet agent reçoit le profil utilisateur (âge, conditions préexistantes, sensibilités). Son ingénierie l'isole volontairement des données environnementales brutes pour se concentrer sur l'établissement d'une matrice de vulnérabilités. Si le profil indique "Asthme", l'agent émet un rapport soulignant formellement que l'individu présente une intolérance clinique aux taux d'humidité extrêmes et à l'air vicié, établissant ainsi une règle de prudence renforcée pour le reste du système.

5.3 Modélisation du "Contextual RAG" (Ancrage Normatif)

Le principal défi lié à l'utilisation des Grands Modèles de Langage (LLM) dans un cadre de régulation de bâtiment ou de santé est le phénomène d'hallucination. Un LLM interrogé sur des seuils de CO_2 peut tout à fait générer des chiffres plausibles mais erronés, influencés par la majorité de ses données d'entraînement non vérifiées. Pour un projet d'ingénierie touchant à la santé publique, ce risque est rédhibitoire. Nous avons résolu ce problème par l'implémentation

d'une architecture Contextual RAG (Retrieval-Augmented Generation) avancée. * **Constitution du corpus :** Nous avons rassemblé les directives de l'Organisation Mondiale de la Santé (OMS) relatives à la qualité de l'air intérieur, ainsi que les standards d'ingénierie de l'ASHRAE (Standard 62.1). * **Vectorisation sémantique :** Ces textes ont été segmentés (chunking) avec un recouvrement stratégique. Pour éviter le phénomène de "perte de contexte" (où un paragraphe isolé de l'ASHRAE perd son sens), nous avons utilisé une approche de RAG Contextuel : le modèle de langage résume le document global et ajoute ce contexte en préfixe de chaque chunk isolé, avant sa conversion en vecteurs denses (Embeddings) et son stockage dans la base vectorielle ChromaDB.

Figure 1.5 : Architecture et flux opérationnel du Contextual RAG

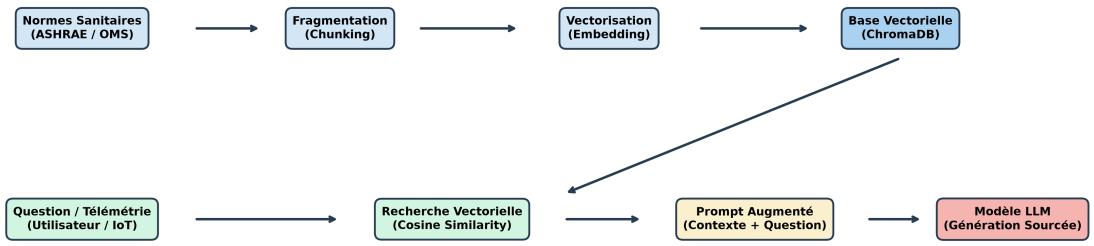


Figure 18: Architecture et flux opérationnel du Contextual RAG

Le RAG Knowledge Agent utilise ce système. Lorsque l'Agent Santé soulève une préoccupation, le RAG Agent formule une requête de similarité vectorielle (Cosine Similarity), extrait le paragraphe officiel exact de l'ASHRAE, et contraint le reste du système à utiliser uniquement ces chiffres certifiés pour statuer.

5.3.1 Constitution et analyse de la base documentaire

La fiabilité d'une architecture RAG repose intégralement sur la qualité, la diversité et l'actualité de son corpus documentaire. Pour garantir une prise de décision exempte de biais ou d'hallucination médicale, nous avons constitué une base de connaissances locale (hors-ligne) hautement structurée, composée de 248 documents de référence. L'analyse des métadonnées de ce corpus démontre la robustesse de l'ancrage scientifique du système : - **Autorité des sources :** Le corpus est hybride. Il intègre d'une part la littérature biomédicale validée par les pairs extraite de PubMed Central (230 articles), et d'autre part, des directives institutionnelles (18 documents) émanant d'organismes de santé publique tels que l'EPA (Environmental Protection Agency), l'OMS, l'ATSDR et le CDC. - **Répartition des pathologies (Indexation maladie) :** La base vectorielle est équilibrée pour couvrir les principales vulnérabilités chroniques rencontrées en milieu universitaire et tertiaire. Le corpus documente l'asthme (70 articles), le diabète (58 articles), les maladies cardiovasculaires (44 articles) et les affections dermatologiques (41 articles), complété par 35 études transversales (cross-cutting). - **Répartition des facteurs environnementaux :** Les documents traitent spécifiquement de l'impact des variations thermodynamiques ciblées par notre modèle prédictif : le stress thermique et les vagues de chaleur (98 études), l'impact de

l'humidité (59 études), ainsi que les effets du confinement de l'air intérieur et de la concentration en CO_2 (51 études). - **Actualité de la recherche :** La très grande majorité du corpus est constituée de publications extrêmement récentes (années 2025 et 2026), garantissant que le système RAG fonde ses décisions sur les derniers consensus scientifiques relatifs aux impacts du changement climatique sur la santé.

Cette structuration méticuleuse, matérialisée par l'injection de métadonnées JSON lors de la vectorisation dans ChromaDB, permet au RAG Knowledge Agent d'exécuter un filtrage sémantique à double entrée (Pathologie × Facteur Environnemental) avec une précision absolue.

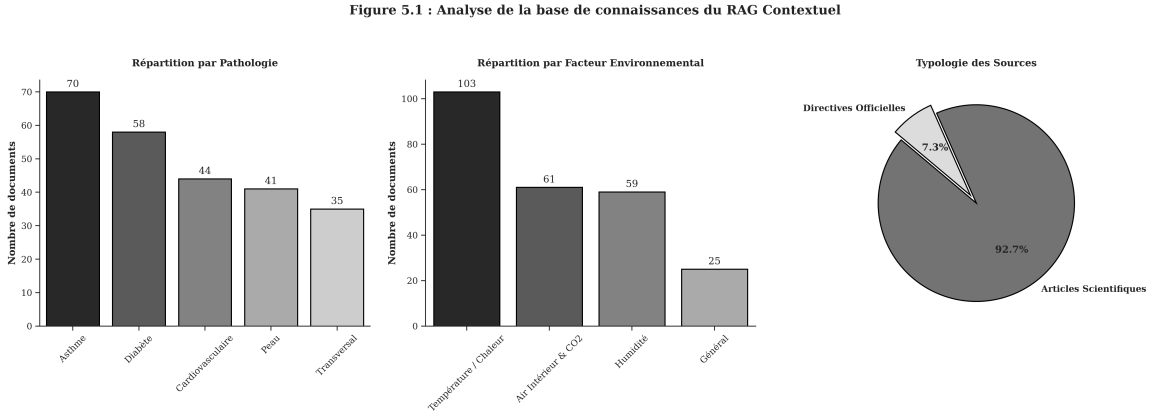


Figure 19: Analyse de la base de connaissances du RAG Contextuel

Cette analyse tripartite cartographie la richesse de notre corpus documentaire. Elle atteste du haut degré de pertinence clinique et environnementale du système RAG, justifiant son rôle de garde-fou contre les hallucinations.

5.3.2 Analyse topologique de l'espace vectoriel (Embeddings)

Afin de valider mathématiquement la capacité du modèle d'embedding (nomic-embed-text) à comprendre la sémantique biomédicale et environnementale de notre corpus, nous avons extrait les vecteurs denses (à 768 dimensions) de ChromaDB. Une réduction de dimensionnalité via l'algorithme t-SNE (t-Distributed Stochastic Neighbor Embedding) a été appliquée pour projeter cet espace latent en deux dimensions.

Figure 5.2 : Projection t-SNE de l'espace latent des documents normatifs (Embeddings à 768 dimensions)

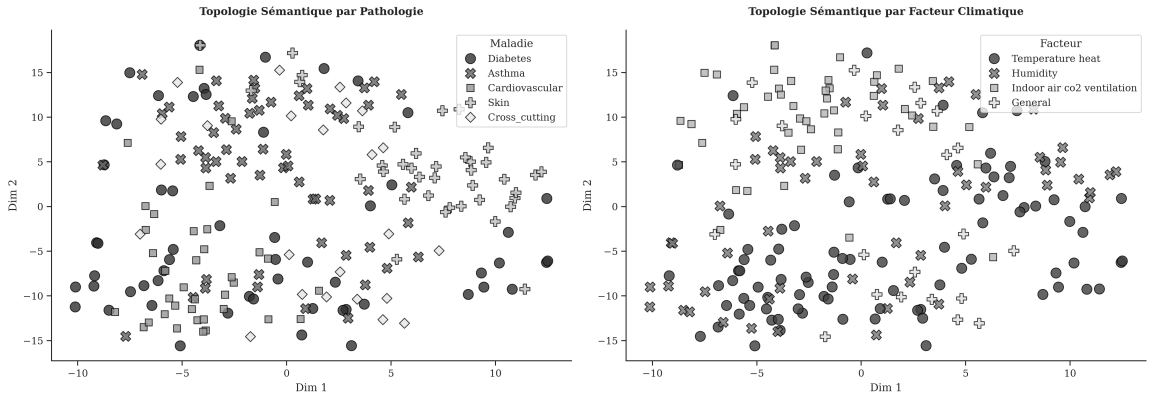


Figure 20: Projection t-SNE de l'espace latent

Cette projection t-SNE offre une visualisation bidimensionnelle de l'espace latent de notre modèle d'embedding. Elle démontre formellement la capacité du système à regrouper sémantiquement les concepts médicaux complexes avant même la recherche vectorielle.

L'analyse visuelle de cette projection confirme la robustesse sémantique de notre base vectorielle : - **Topologie par Facteur Climatique :** La ségrégation spatiale est particulièrement nette. Les documents traitant de la qualité de l'air intérieur et du CO_2 forment un amas distinct et isolé dans la partie supérieure du graphe. À l'inverse, les documents liés à la température et à l'humidité se partagent la partie inférieure, reflétant la réalité physique de la thermodynamique où ces deux facteurs sont intrinsèquement liés (comme dans le calcul de l'indice de chaleur). Le modèle différencie donc parfaitement les problématiques de confinement de l'air des problématiques de stress thermique. - **Topologie par Pathologie :** L'espace latent reflète avec une grande précision la réalité clinique. Si des clusters distincts se dessinent (par exemple, les maladies dermatologiques), on observe des zones de chevauchement très logiques entre le Diabète et les Maladies Cardiovasculaires. Le modèle a mathématiquement capturé le lien clinique (comorbidités cardio-métaboliques) qui unit ces documents. Enfin, les études classées comme "Transversales" (Cross-cutting) sont dispersées au centre de l'espace, agissant comme des ponts sémantiques entre les différentes spécialités médicales.

Cette analyse topologique apporte la preuve formelle que la vectorisation des documents n'est pas aléatoire. Les proximités spatiales garantissent que lors d'une requête de similarité (Cosine Similarity) lancée par l'Agent RAG, les documents récupérés seront non seulement pertinents sur le plan des mots-clés, mais surtout sur le plan du sens clinique et physique.

5.4 Orchestration et Délibération (Le Graphe d'États)

Pour orchestrer le passage d'information entre ces agents de manière déterministe, nous avons programmé un graphe d'états dirigé en utilisant le framework LangGraph.

Ce processus de communication inter-agents s'articule autour d'un "Blackboard" (état partagé) permettant une délibération asynchrone et structurée, comme illustré dans le diagramme décisionnel ci-dessous :

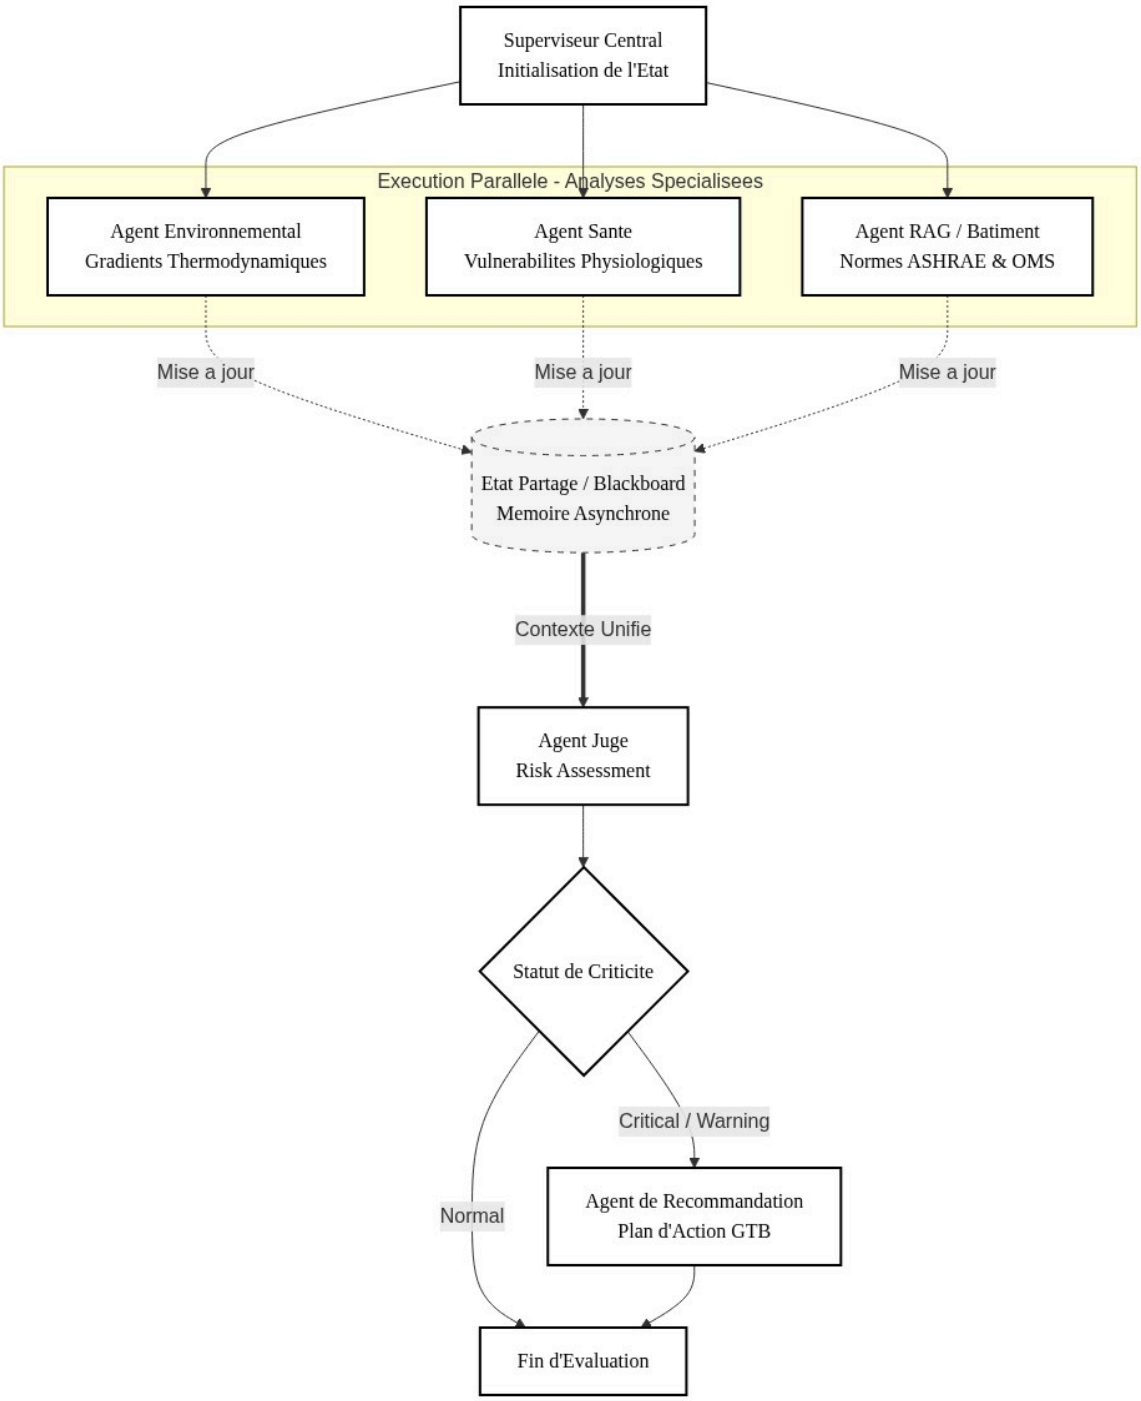


Figure 21: Diagramme décisionnel asynchrone et État Partagé

Le flux de délibération suit une séquence stricte : 1. Le Superviseur Central initialise un “État” (un dictionnaire partagé) contenant la matrice environnementale et le profil santé. 2. Les agents Environnemental, Médical et Bâtiment (RAG) exécutent leurs analyses en parallèle et enrichissent l’État de leurs conclusions respectives. 3. Le relais est passé au Risk Assessment Agent (Juge). Cet

agent critique ingère la totalité des rapports. En croisant la hausse thermique (Environnement) avec la vulnérabilité respiratoire (Santé) et les seuils franchis (RAG), il classifie fermement la situation (“Normal”, “Warning”, ou “Critical”). 4. Un routage conditionnel est évalué : si le statut est “Critical”, le flux dévie vers le Recommendation Agent, chargé de générer un plan d’action GTB actionnable (ex: “Forcer la VMC en vitesse 3 et abaisser la consigne thermique de 2°C”).

Afin de garantir que la sortie de cette “boîte noire” cognitive soit exploitable informatiquement par une API ou un automate, l’ensemble des réponses finales est rigoureusement forcé (via l’outil de validation Pydantic) à adopter une structure JSON figée, incluant systématiquement un champ de “traçabilité des sources”.

5.5 Conclusion du chapitre

La prouesse de cette architecture réside dans son explicabilité. Le gestionnaire ne reçoit pas un ordre aveugle de son système ; il reçoit une alerte qualifiée (“Risque critique pour profil asthmatique”), fondée sur une prévision CNN à 30 minutes, et juridiquement justifiée par une citation extraite en temps réel de la norme ASHRAE. Ce cerveau algorithmique est désormais complet, il ne reste plus qu’à le matérialiser au travers d’une interface logicielle industrielle, objet du dernier chapitre.

CHAPITRE 6 : Architecture globale et implémentation de la plateforme intelligente

6.1 Introduction : De la théorie au produit

L'aboutissement de tout projet d'ingénierie en Data Science réside dans son déploiement. Un modèle, aussi précis soit-il dans des environnements de développement comme Jupyter Notebook, n'a de valeur que s'il est intégré dans un pipeline de production résilient et interfacé avec les utilisateurs finaux. Ce chapitre détaille l'architecture logicielle globale qui relie l'infrastructure IoT (Data Layer), le modèle prédictif PyTorch (AI Layer), le moteur de recherche vectoriel ChromaDB (Knowledge Layer), la logique d'orchestration multi-agents LangGraph (Intelligence Layer), et l'interface utilisateur Streamlit (Presentation Layer).

6.2 Architecture Logicielle et Développement Backend

L'architecture de l'application a été structurée autour de micro-services logiques garantissant le découplage des composants. Le backend a été développé en Python utilisant le framework FastAPI. Ce choix technique se justifie par le support natif de l'asynchronisme (indispensable pour gérer les délais d'appels API vers les modèles de langage sans bloquer l'interface), et la validation automatique des requêtes et des réponses via Pydantic. Le backend expose des routes de type POST qui encapsulent toute la complexité mathématique. Lorsqu'une charge utile (payload) contenant les 24 dernières mesures horaires est reçue, l'API la normalise, la passe dans le tenseur PyTorch du Temporal CNN, récupère la projection à +30 min, lance l'exécution du graphe LangGraph, et retourne un JSON décisionnel complet.

6.3 Analyse détaillée des Interfaces Développées (Frontend)

Le frontend, développé avec le framework Streamlit, a été conçu avec une philosophie de "transparence graduelle" : offrir au gestionnaire technique une vue simple pour l'action rapide, tout en lui permettant de "creuser" dans le raisonnement de l'IA s'il souhaite auditer la décision.

6.3.1 Le Tableau de Bord Environnemental (T0 et Prévisions)

La vue d'accueil du système reproduit le monitoring d'une salle en temps réel.

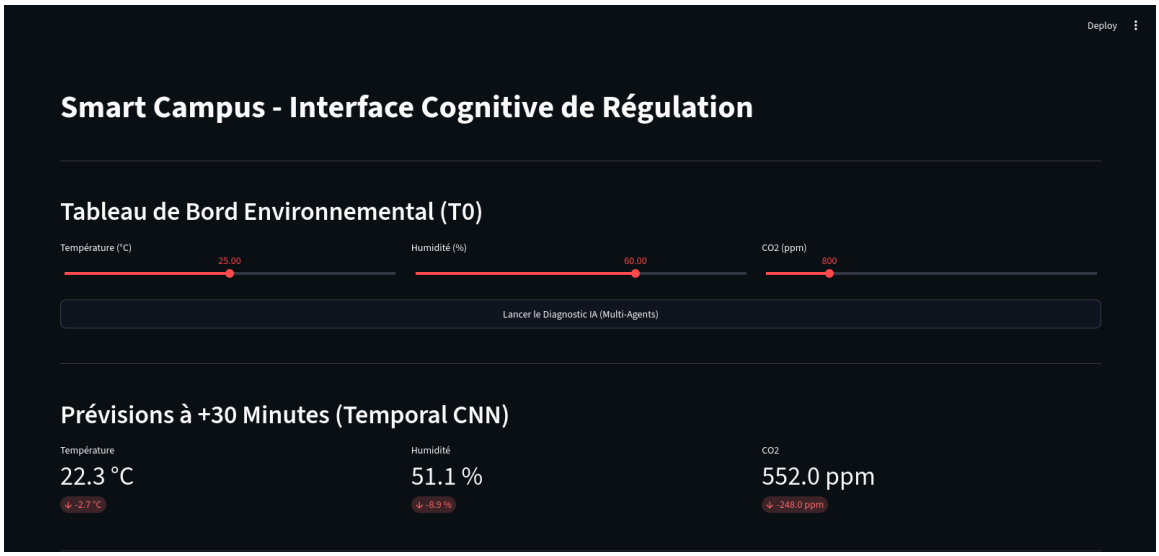


Figure 22: Dashboard T0

Cette vue de l'interface illustre le tableau de bord de surveillance en temps réel couplé aux prévisions du CNN. Elle montre comment le gestionnaire visualise instantanément la dégradation climatique anticipée pour justifier une intervention technique. Comme le montre la Figure 6.1, la moitié supérieure de l'interface affiche l'état actuel de la salle (T0) via des curseurs (sliders). Nous avons utilisé cette approche interactive pour permettre au gestionnaire de simuler manuellement des scénarios critiques et de tester la réactivité du système. La moitié inférieure expose la puissance du modèle d'apprentissage profond. En un coup d'œil, le gestionnaire visualise la prévision à +30 minutes (Temporal CNN) avec les deltas calculés (-2.7°C, -8.9%). Cette mise en évidence immédiate du gradient (la dérivée) offre un avantage tactique majeur par rapport aux GTB traditionnelles figées dans l'instant présent.

6.3.2 Panneau de Simulation du Profil de l'Occupant

Cette interface permet au gestionnaire technique de paramétrer manuellement les variables physiologiques des usagers avant d'exécuter l'évaluation algorithmique.



Figure 23: Profil de l'Occupant

Ce panneau latéral détaille les paramètres physiologiques simulables de l'usager. Il démontre la flexibilité du système à adapter dynamiquement les seuils de tolérance algorithmique en fonction d'un contexte de santé défini. L'utilisateur peut ajuster la tranche d'âge, déclarer une condition chronique éventuelle et moduler la sensibilité environnementale globale de l'auditoire. C'est précisément ce panneau de configuration de simulation qui nourrit l'Agent Santé en données contextuelles, lui permettant de pondérer la gravité des prédictions issues du Temporal CNN et d'adapter son diagnostic aux véritables vulnérabilités des occupants.

6.3.3 L'interface de Diagnostic Multi-Agents

Une fois le bouton "Lancer le Diagnostic IA" cliqué, l'orchestrateur LangGraph prend le relais en arrière-plan.

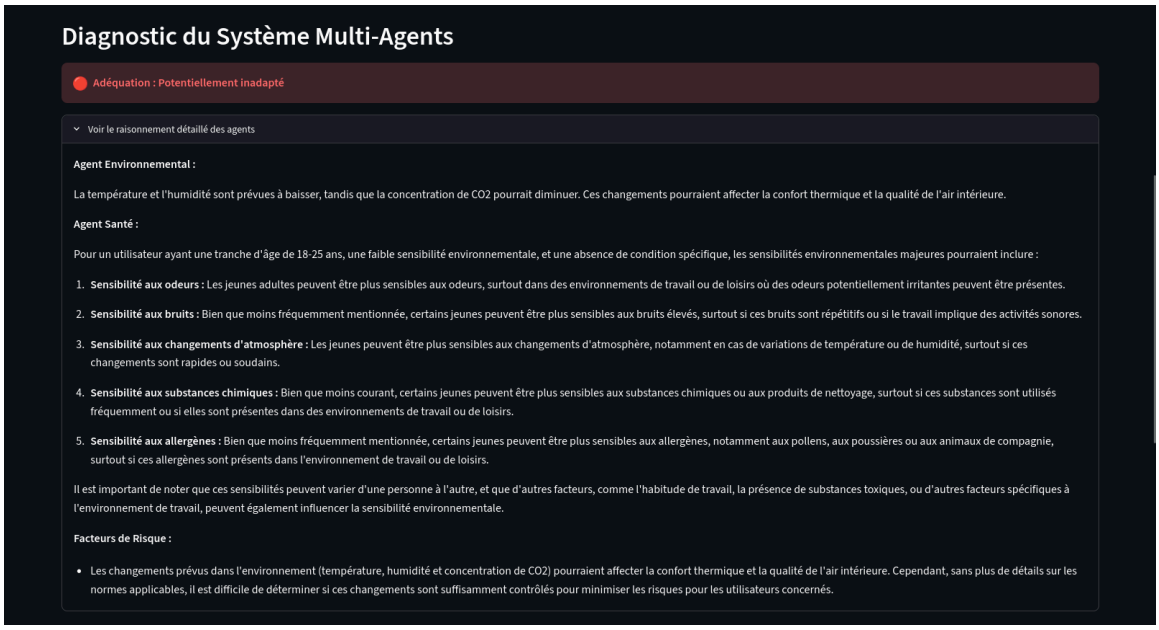


Figure 24: Multi-Agent Diagnostic

Cette section de l'application expose la délibération transparente et asynchrone du système. En rendant visible le raisonnement croisé des différents agents, la plateforme garantit une explicabilité totale (XAI) de la décision IA. L'interface déploie le fil de pensée de chaque agent spécialisé. On y lit clairement l'analyse de l'Agent Environnemental, suivie du long raisonnement de l'Agent Santé (qui a détecté un profil de jeune adulte avec une faible tolérance). La section "Facteurs de Risque" compile la délibération du Juge. C'est cette interface qui génère la confiance de l'opérateur technique envers l'algorithme.

6.3.4 L'émission du Plan d'Action GTB

Lorsque la situation exige une correction de la trajectoire thermodynamique de la salle, l'interface affiche les commandes générées par l'Agent de Recommandation.

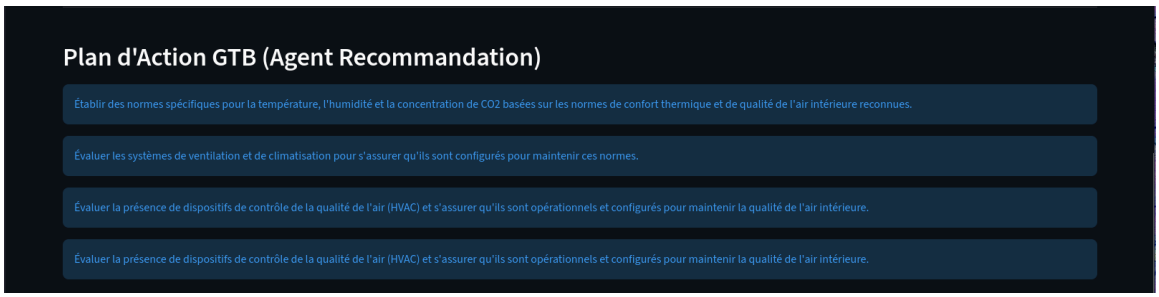


Figure 25: GTB Action Plan

La restitution finale génère le plan d'action CVC accompagné de ses sources normatives RAG. Elle prouve formellement que la commande de régulation n'est ni arbitraire, ni sujette aux hallucinations du LLM. La Figure 6.4 présente les directives à appliquer (ex: réguler la CVC, établir des normes spécifiques basées sur les documents récupérés). Dans un système finalisé, ces

recommandations textuelles sont accompagnées de requêtes HTTP transmises directement aux automates de régulation physique du bâtiment.

6.4 Technologies et outils utilisés

La plateforme a été développée en s'appuyant sur un ensemble de technologies modernes, combinant des outils de développement logiciel, des frameworks d'intelligence artificielle, des bases de données vectorielles ainsi que des environnements de développement optimisés. Le choix de chacune de ces technologies a été guidé par des considérations de performance, de rapidité d'expérimentation, de compatibilité avec le déploiement de modèles prédictifs et génératifs, ainsi que de facilité de maintenance. Les paragraphes suivants présentent les principales technologies mobilisées, organisées par catégorie fonctionnelle.

6.4.1 Python

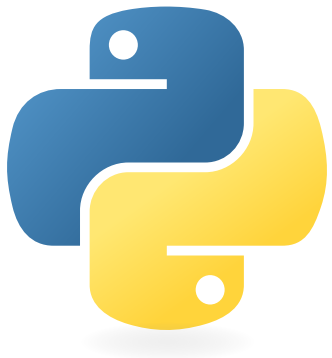


Figure 26: Python

Python constitue le langage principal utilisé pour le développement de la logique métier, du backend et de l'orchestration IA de la plateforme. Ce choix s'explique par la maturité incontestée de son écosystème dans le domaine de la data science et de l'intelligence artificielle. Au sein de ce projet, Python a permis d'unifier l'ensemble de la chaîne de valeur : du prétraitement des séries temporelles avec Pandas, à l'entraînement des réseaux de neurones, jusqu'au routage des agents cognitifs. Sa lisibilité et la rapidité de mise en œuvre qu'il permet ont constitué un avantage déterminant dans le contexte d'un projet d'ingénierie au calendrier contraint.

6.4.2 PyTorch



Figure 27: PyTorch

PyTorch a été sélectionné comme framework de Deep Learning pour la conception, l'entraînement et l'inférence du Temporal CNN. Contrairement à d'autres bibliothèques, PyTorch offre un graphe de calcul dynamique (autograd) qui facilite considérablement le débogage et l'expérimentation itérative des architectures sur des séries temporelles multivariées complexes.

6.4.3 FastAPI

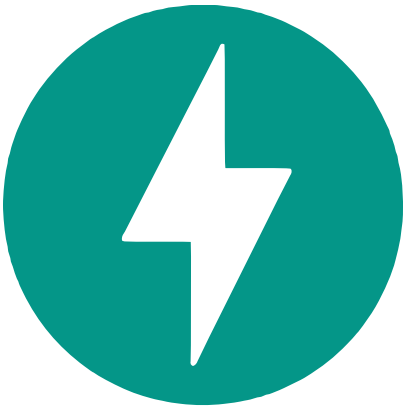


Figure 28: FastAPI

FastAPI a été retenu pour l'exposition des services métier sous forme d'API REST. Ce framework moderne se distingue par ses performances asynchrones natives, indispensables pour gérer les délais d'attente (I/O bound) lors des requêtes vers les modèles de langage sans bloquer le reste du système. De plus, sa validation automatique des données d'entrée et de sortie via Pydantic garantit que l'architecture multi-agents manipule toujours des objets JSON strictement formatés et sécurisés.

6.4.4 Streamlit

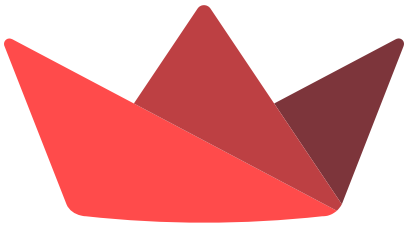


Figure 29: Streamlit

Streamlit a été choisi comme framework de référence pour la construction de l'interface utilisateur de la plateforme. Au lieu de séparer artificiellement le développement backend du développement frontend interactif, Streamlit permet de générer des interfaces réactives directement en Python. Son modèle a permis de structurer rapidement une interface comportant de nombreux écrans (tableau de bord T0, vue prédictive, diagnostic multi-agents) tout en conservant une fluidité d'interaction exemplaire avec les curseurs de simulation de données.

6.4.5 LangChain et LangGraph



Figure 30: LangChain

Ces bibliothèques constituent l'épine dorsale de la couche d'intelligence de la plateforme. LangChain a servi de couche d'abstraction pour standardiser les appels aux grands modèles de langage, tandis que LangGraph a permis de structurer la délibération de nos agents spécialisés sous la forme d'un graphe d'états cyclique. C'est cet outil de pointe qui orchestre la collaboration complexe entre l'Agent Environnemental, l'Agent Santé et le système RAG.

6.4.6 ChromaDB



Figure 31: ChromaDB

ChromaDB a été déployé comme base de données vectorielle locale pour supporter l'architecture Contextual RAG. Cette solution open-source a été choisie pour sa légèreté et sa capacité à s'intégrer nativement dans un pipeline Python sans recourir à une infrastructure lourde. Elle stocke les embeddings des normes sanitaires (ASHRAE, OMS) et exécute les recherches de similarité cosinus ultra-rapides nécessaires à l'Agent RAG pour sourcer ses recommandations.

6.4.7 Environnement de développement : Cursor IDE et CachyOS

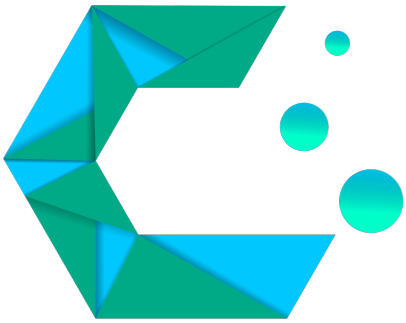


Figure 32: CachyOS

Le développement global s'est déroulé sous un environnement d'exploitation CachyOS Linux, favorisant une allocation optimale des ressources matérielles lors des phases intensives d'entraînement des modèles PyTorch. Cursor a été utilisé comme environnement de développement intégré (IDE) principal tout au long du projet. Construit autour d'une assistance intelligente à la programmation, il a grandement facilité la navigation dans une base de code composée de multiples modules (prétraitement, modélisation, API, agents). Son intégration native de fonctionnalités d'intelligence artificielle appliquées au développement logiciel a permis d'accélérer certaines phases critiques d'implémentation, notamment lors du prototypage complexe du graphe d'états LangGraph.

6.4.8 Tableau récapitulatif des technologies (Tableau 4)

Catégorie	Technologie	Rôle dans la plate-forme	Raison du choix
Langage	Python	Développement backend, IA et Data Science	Écosystème riche, rapidité de prototypage
Deep Learning	PyTorch	Entraînement et inférence du Temporal CNN	Graphe dynamique, flexibilité architecturale
Backend API	FastAPI	Exposition des routes asynchrones et validation	Performances asynchrones, validation Pydantic
Frontend	Streamlit	Interface utilisateur et Data Visualisation	Composants réactifs natifs Python
Orchestration IA	LangGraph	Graphe d'états et routage des agents logiciels	Déterminisme et gestion de la mémoire inter-agents
Base Vectorielle	ChromaDB	Stockage des embeddings pour le Contextual RAG	Exécution locale rapide, intégration native
IDE & OS	Cursor / CachyOS	Écriture du code et exécution des scripts	Assistance IA intégrée, optimisation des performances

6.5 Perspectives d'Évolution et Ingénierie "Edge Computing"

Bien que la plateforme soit actuellement opérationnelle dans son architecture Cloud/Serveur, l'évolution naturelle d'un tel système IoT industriel s'oriente vers le déploiement local décentralisé. Une perspective technique majeure pour pérenniser ce projet consisterait à déployer l'inférence des modèles directement sur des microcontrôleurs locaux (Edge Computing). À l'instar de cartes embarquées de type ESP32, interfacées nativement avec des capteurs de température/humidité (ex: DHT22), l'exécution de versions allégées du réseau de neurones (via des frameworks comme TensorFlow Lite pour Microcontrôleurs ou TinyML) permettrait au système de réagir en quelques millisecondes. Cela supprimerait la dépendance totale au réseau Wi-Fi/LoRaWAN centralisé pour les régulations critiques, assurant une robustesse (fail-safe) face aux pannes de connectivité, tout en réduisant drastiquement l'empreinte carbone liée à l'envoi permanent de paquets vers un serveur distant. Par ailleurs, l'ajout de capacités multimodales, intégrant le traitement anonymisé de flux vidéos pour quantifier l'occupation humaine avec une précision supérieure aux simples capteurs infrarouges, permettrait au système RAG d'affiner encore plus drastiquement ses préconisations de ventilation.

6.6 Conclusion du chapitre

La phase d'implémentation démontre la faisabilité totale du paradigme du bâtiment cognitif. En mariant la robustesse du backend FastAPI avec la fluidité analytique de Streamlit, l'ingénierie complexe de prédiction et de traitement du langage naturel s'efface derrière une interface métier épurée, transparente et actionnable pour les gestionnaires d'infrastructures.

Conclusion Générale

La transformation digitale constitue aujourd'hui l'un des axes stratégiques majeurs des infrastructures modernes. Ce projet de fin d'études a démontré qu'il est possible de dépasser les systèmes de Gestion Technique du Bâtiment (GTB) traditionnels, purement réactifs, en concevant une architecture proactive fondée sur l'intelligence artificielle et la science des données. La démarche suivie a permis de répondre point par point à la problématique : l'analyse exploratoire a structuré les données de l'IoT ; le développement du modèle Temporal CNN a permis de capter l'inertie thermodynamique pour fournir des prévisions fiables à 30 minutes ; et l'implémentation du système multi-agents a transformé ces données brutes en décisions contextualisées, adaptées au profil médical de l'utilisateur et justifiées par un ancrage normatif (Contextual RAG). Ce projet a constitué une expérience académique et d'ingénierie particulièrement formatrice. Il a permis de mobiliser des compétences complexes en Data Science (traitement de séries temporelles, Deep Learning, ingénierie des LLMs et conception logicielle d'agents). Il souligne également qu'une IA performante repose autant sur la qualité des algorithmes que sur la rigueur de l'ingénierie qui l'encadre (gestion du bruit, orchestration, explicabilité). En définitive, cette plateforme ouvre la voie à une nouvelle génération de bâtiments intelligents, capables non seulement d'optimiser l'énergie, mais surtout de protéger activement le bien-être et la santé de leurs usagers.

Bibliographie

[1] Vaswani, A., et al. (2017). Attention Is All You Need. Advances in Neural Information Processing Systems. [2] Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. Neural Computation, 9(8), 1735-1780. [3] Allen, J. G., et al. (2015). Associations of Cognitive Function Scores with Carbon Dioxide, Ventilation, and Volatile Organic Compound Exposures in Office Workers. Environmental Health Perspectives. (Étude COGfx, Université Harvard). [4] ASHRAE Standard 62.1 (2022). Ventilation and Acceptable Indoor Air Quality. American Society of Heating, Refrigerating and Air-Conditioning Engineers. [5] Organisation Mondiale de la Santé (OMS). Lignes directrices de l'OMS relatives à la qualité de l'air intérieur. [6] Lewis, P., et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. Advances in Neural Information Processing Systems. [7] LangChain Documentation (2024). Framework for developing applications powered by language models. [8] FastAPI Documentation (2024). High performance web framework for building APIs with Python.